گزارش پروژه دوم – مصور سازی و بررسی مدل های پیشگو روی داده های مربوط به خرید و فروش مسکن

استان خوزستان

مجتبی کنعانی سرچشمه

در این پروژه قصد داریم داده های مربوط به خرید و فروش مسکن در استان خوزستان را مصورسازی کنیم.

اطلاعات مربوط به کل استان ها از ۴۳۱۳۳ داده و ۱۵ متغیر تشکیل شده است. که ۷۶۸ عدد از این داده ها اطلاعات مربوط به استان خوزستان است.

ابتدا به طور مختصر به معرفی ستون های داده میپردازیم.

۱. کد قرارداد : نمونه ای از داده های این ستون به شکل زیر است

```
$ کد قرارداد          : chr [1:43133] "19136381" "19140513" "19192568" "19202902" ...
```

این ستون اطلاعات خاصی در اختیار ما قرار نمیدهد.

۲. نوع قرارداد : نمونه ای از داده های این ستون به شکل زیر است

```
$ نوع قرارداد         : chr [1:43133] "مبایعه نامه" "مبایعه نامه" "مبایعه نامه" "مبایعه نامه" ...
```

مقادیر تمام داده های مربوط به این ستون برابر با "مبایعه نامه" است و اطلاعات خاصی در اختیار ما قرار نمیدهد.

۳. استان : نمونه ای از داده های این ستون به شکل زیر است

```
$ استان               : chr [1:43133] "زنجان" "زنجان" "زنجان" "زنجان" ...
```

به داده هایی نیاز داریم که مقادیر آن ها در این ستون برابر با "خوزستان" باشد.

٤. شهرستان : نمونه ای از داده های این ستون به شکل زیر است

```
$ شهرستان            : chr [1:43133] "ابهر" "ابهر" "ابهر" "ابهر" "ابهر" ...
```

۵. نوع ملک : نمونه ای از داده های این ستون به شکل زیر است

```
$ نوع ملک             : chr [1:43133] "دستگاه آپارتمان" "دستگاه آپارتمان" "دستگاه آپارتمان" "دستگاه آپارتمان" ...
```

مقادیر تمام داده های مربوط به این ستون برابر با "دستگاه آپارتمان" است و اطلاعات خاصی در اختیار ما قرار نمیدهد.

٦. منطقه شهرداری : نمونه ای از داده های این ستون به شکل زیر است

```
$ منطقه شهرداري       : num [1:43133] NA NA NA NA NA NA NA NA NA 4 ...
```

اطلاعات این ستون فقط برای برخی شهرستان ها در برخی استان ها مقدار گرفته است، به همین دلیل نمیتوانیم از این ستون نیز استفاده کنیم

۷. نوع کاربری : نمونه ای از داده های این ستون به شکل زیر است

```
$ نوع کاربري          : chr [1:43133] "مسکوني" "مسکوني" "مسکوني" "مسکوني" ...
```

مقادیر تمام داده های مربوط به این ستون برابر با "مسکونی" است و اطلاعات خاصی در اختیار ما قرار نمیدهد.

۸. مساحت : مساحت ساختمان به متر مربع . نمونه ای از داده های این ستون به شکل زیر است

```
$ مساحت               : num [1:43133] 83 90 49 80.9 80 ...
```

۹. درصد : درصد فروش رفته از ساختمان در معامله . نمونه ای از داده های این ستون به شکل زیر است

```
$ درصد                : chr [1:43133] "100" "100" "100" "100" ...
```

۱۰. قیمت : قیمت کل ساختمان به هزار ریال. نمونه ای از داده های این ستون به شکل زیر است

```
$ قیمت                : num [1:43133] 3000000 1080000 10000000 3240000 750000 ...
```

۱۱. قیمت یک متر مربع : نمونه ای از داده های این ستون به شکل زیر است

```
$ قیمت یک مترمربع     : chr [1:43133] "36144.58" "12000.00" "204081.63" "40039.55" ...
```

۱۲. عمر بنا : نمونه ای از داده های این ستون به شکل زیر است

```
$ عمر بنا             : num [1:43133] 15 9 10 9 10 0 1 6 19 0 ...
```

۱۳. نوع اسکلت : نمونه ای از داده های این ستون به شکل زیر است

```
$ نوع اسکلت           : chr [1:43133] "فلزي" "بتوني" "فلزي" "فلزي" ...
```

۱٤. تاریخ ثبت قرارداد : نمونه ای از داده های این ستون به شکل زیر است

```
$ تاریخ ثبت قرارداد   : chr [1:43133] "1399/04/14" "1399/04/15" "1399/04/23" "1399/04/24" ...
```

اطلاعات خاصی در اختیار ما قرار نمیدهد چون این اطلاعات مربوط به یک بازه یک ماهه میباشد و در این بازه کوتاه نمیتوان تاثیر زمان بر تغییرات مختلف در داده ها را به درستی بررسی کرد و نتیجه گیری های مطمئن از آن ها استخراج کرد.

۱۵. شش رقم نخست کد پستی : نمونه ای از داده های این ستون به شکل زیر است

```
$ شش رقم نخست کد پستي: chr [1:43133] "456179" "456615" "456173" "456194" ...
```

همان طور که گفته شد تعداد زیادی از این ستون ها اطلاعات خاصی به ما نمیدهند و باید قبل از کار با داده ها این اطلاعات کنار بگذاریم.

ستون هایی که در ادامه کار به آن ها نیاز داریم عبارتند از:

استان – شهر – مساحت – قیمت – قیمت هر متر مربع – عمر بنا – نوع اسکلت – شش رقم آخر کد پستی

که برای سادگی کار با داده ها نام این ستون ها را به ترتیب به شکل زیر در می آوریم.

State – city – area – price – price_per_square – building_age – skeleton_type – postal_code

همچنین برای خوانا تر شدن اعداد موجود برای قیمت و قیمت هر متر مربع ، این اطلاعات را به شکل واحد میلیون تبدیل میکنیم.

برای شروع کار ابتدا در نقشه ایران نگاهی به موقعیت مکانی استان خوزستان و شهرستان های این استان می اندازیم.

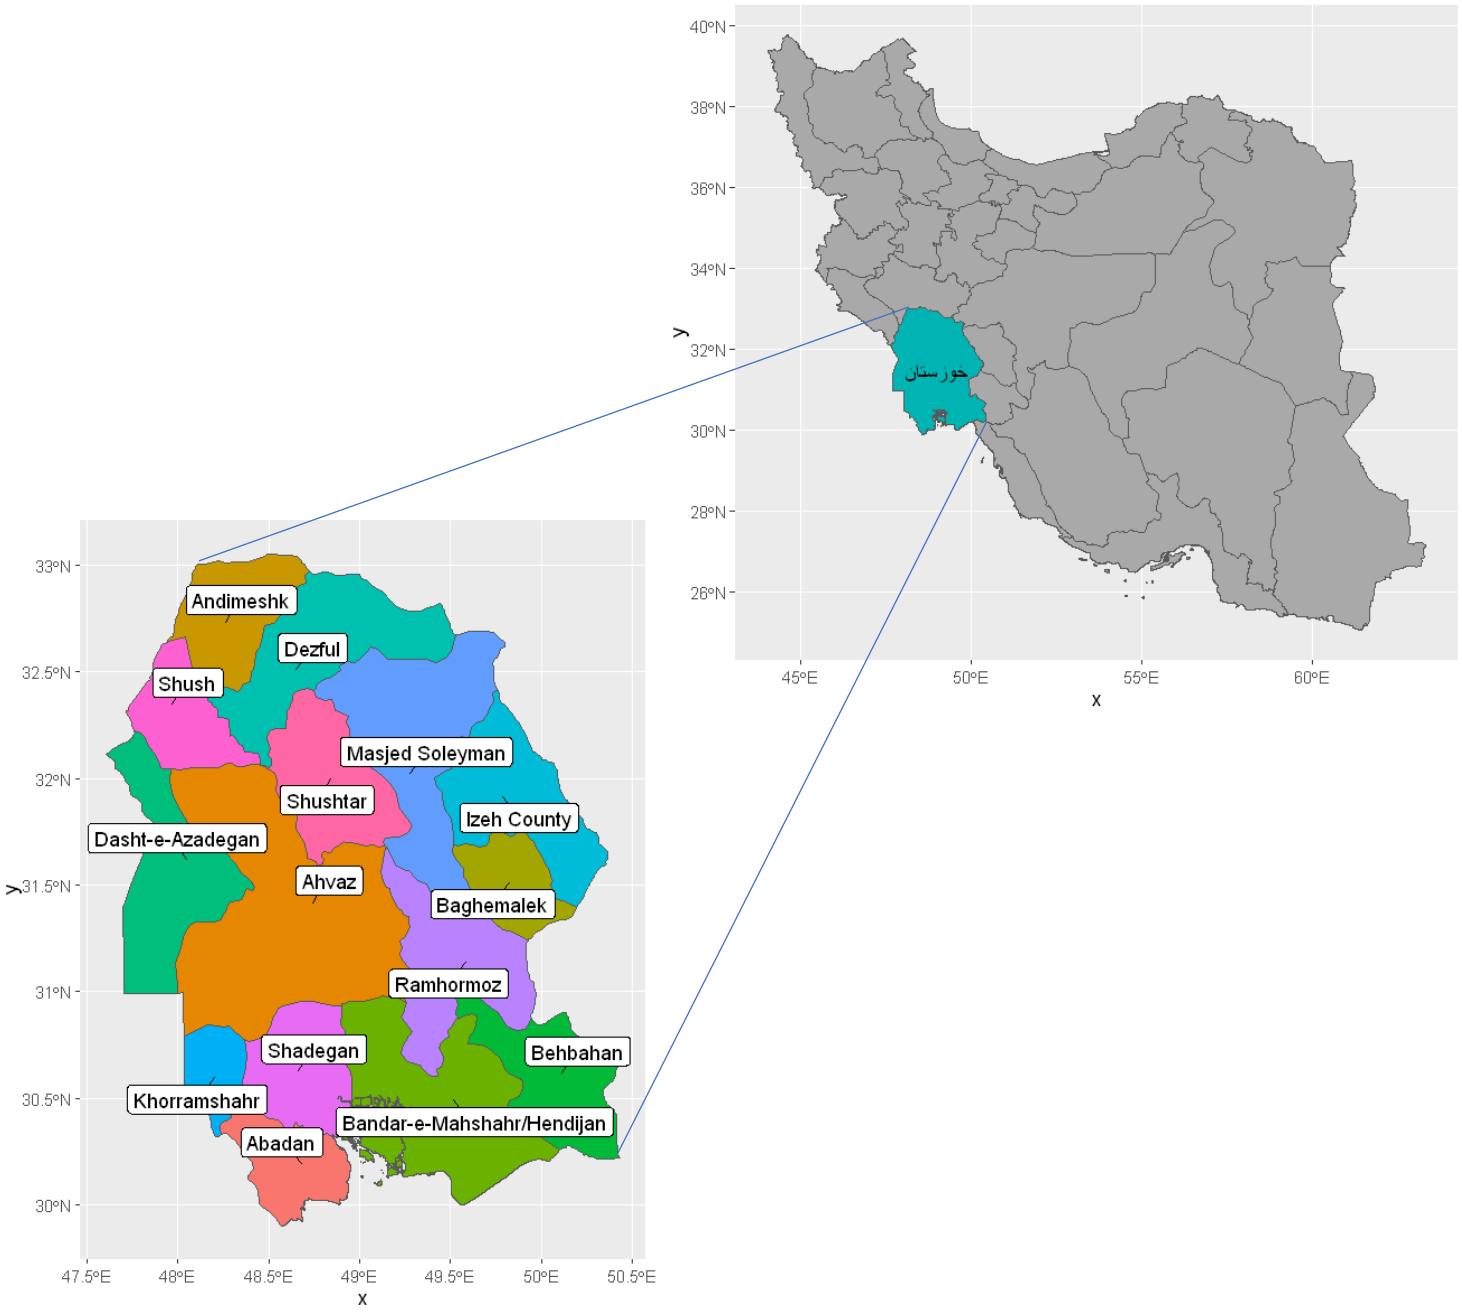

برای بررسی وضعیت قیمت در استان خوزستان نسبت به دیگر استان ها ابتدا نمودار جعبه ای قیمت ساختمان در استان های مختلف را رسم میکنیم.

```
options(repr.plot.width = 8, repr.plot.height = 5)
ggplot(data, aes(x=price_per_square, y=reorder(state, price_per_square, FUN=median) , fill=state)) +
    geom_boxplot(outlier.colour="red", outlier.shape=16,outlier.size=1) +
    labs(title="نمودار جعبه ای قیمت هر متر مربع ساختمان در استان های مختلف", x="قیمت هر متر مربع ساختمان به میلیون تومان", y = "نام استان") +
    theme(legend.position="none",plot.title = element_text(hjust = 0.5))
```

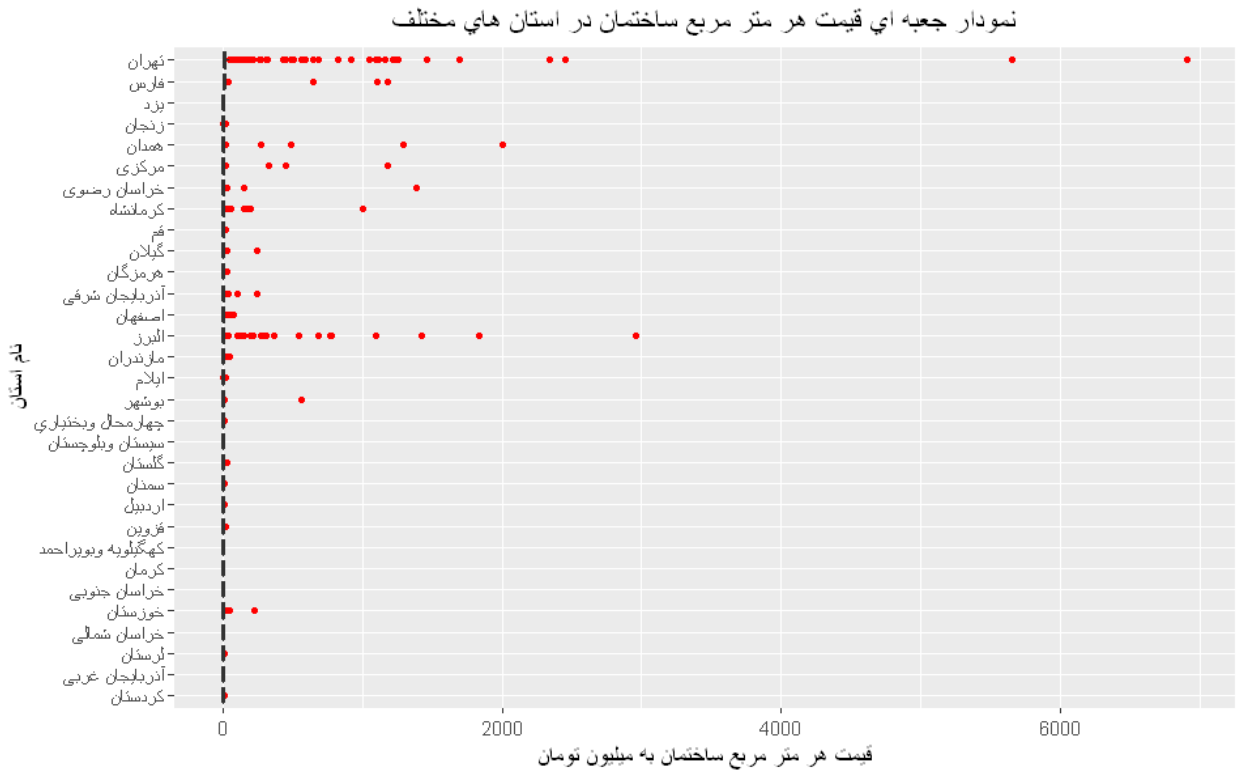

همان طور که مشاهده میکنید به دلیل وجود داده های پرت نمیتوانیم درک درستی از داده های به دست آوریم، به همین دلیل میتوانیم موقتا برخی داده های پرت را کنار بگذاریم تا بتوانیم بخش اصلی داده ها را دقیق تر بررسی کنیم، به همین منظور این نمودار را دوباره رسم میکنیم با این تفاوت که به جای رسم اطلاعات مربوط به تمام داده ها، اطلاعات داده هایی را رسم میکنیم که قیمت ساختمان در آن ها در ۹ دهک اول قیمتی وجود داشته باشد، به این ترتیب داده های بسیار بزرگی که وجود دارد را کنار میگذاریم.

```
options(repr.plot.width = 8, repr.plot.height = 5)
ggplot(data[data$price_per_square < quantile(data$price_per_square,0.9),],
    aes(x=price_per_square, y=reorder(state, price_per_square, FUN=median) , fill=state)) +
    geom_boxplot(outlier.colour="black", outlier.shape=16,outlier.size=1) +
    labs(title="نمودار جعبه ای قیمت هر متر مربع (9 دهک اول) ساختمان در استان های مختلف", x="قیمت هر متر مربع ساختمان به میلیون تومان", y = "نام استان") +
    theme(legend.position="none",plot.title = element_text(hjust = 0.5))
```

Quantile دستوری است که برای این کار استفاده میکنیم تا مرز بین دهک نهم و دهم را پیدا کنیم و داده های را از آن جا به دو بخش تقسیم کنیم. از دستور reorder نیز استفاده میکنیم تا این نمودار های جعبه ای را به ترتیب میانه در نمودار بچینیم تا دید بهتری به ما دهد.

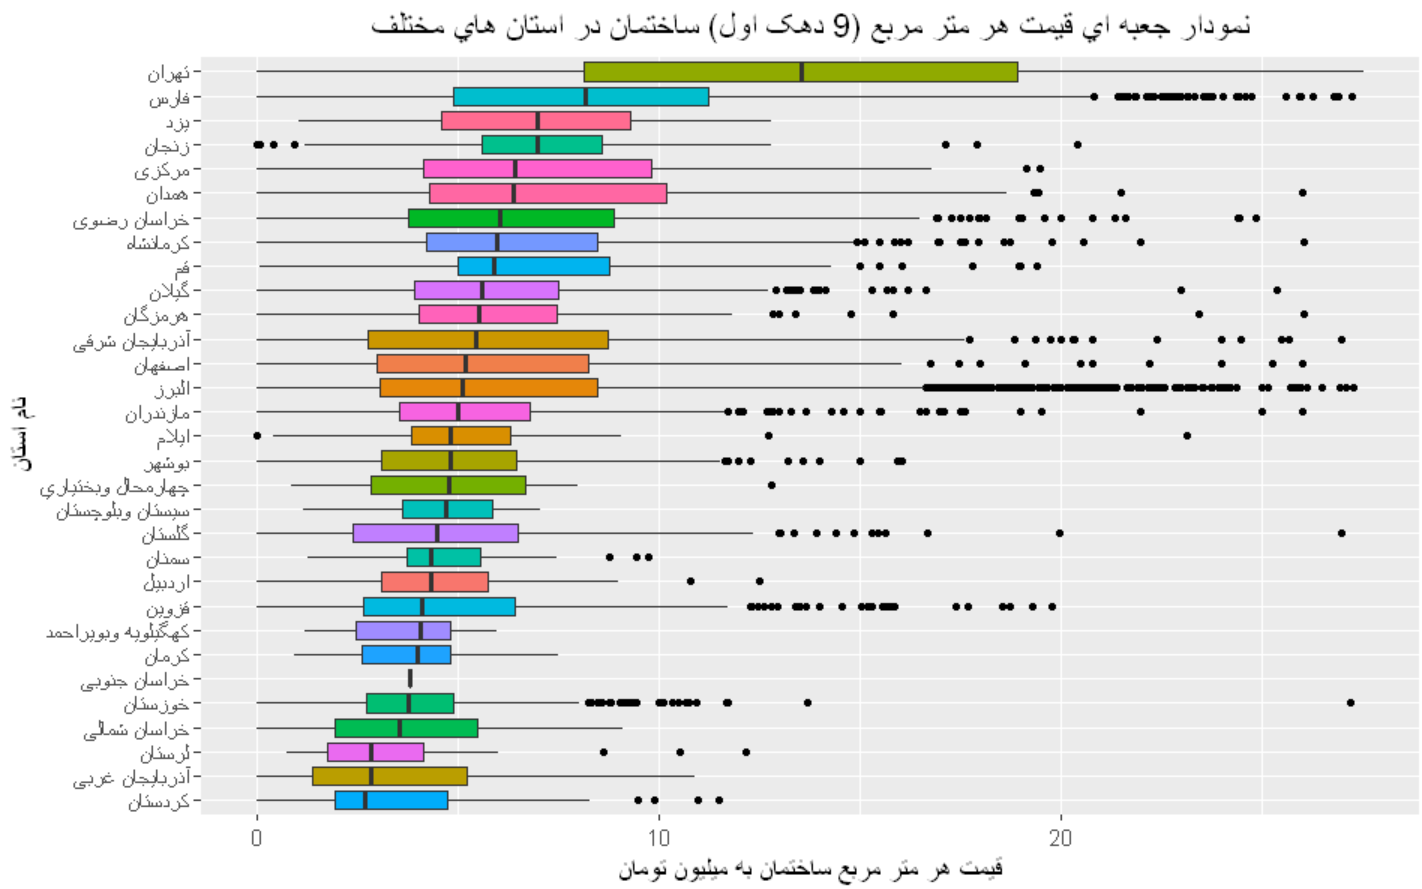

همان طور که مشاهده میکنید با این کار توانستیم درک بهتری نسبت به داده ها پیدا کنیم و همان طور که از نمودار واضح است با توجه به میانه قیمت ها در استان های مختلف ، استان خوزستان در رده پنجم استان های ارزان کشور است.

برای ادامه کار قصد داریم داده های مربوط به استان خوزستان را دقیق تر بررسی کنیم بنابراین داده هایی که مقدار آن ها در ستونstate برابر با "خوزستان" است را جدا میکنیم.

```
khoozestan = data[data$state == 'خوزستان',]
```

در ابتدا قصد داریم همبستگی بین ستون ها را بررسی کنیم ، برای این کار نیاز داریم تا تمام داده های کیفی را به کمک dummy variable ها به شکل داده های کمّی دربیاوریم تا بتوانیم مقدار correlation را برای آن ها به دست بیاوریم. داده های کیفی این dataframe در ستون های city و building_type میباشد.

برای این کار از دستور زیر استفاده میکنیم.

```
df<-khoozestan %>%
    select('city','area','building_age','skeleton_type','price','price_per_square')
```

```
df = dummy_cols(df, select_columns = c('city', 'skeleton_type'),remove_selected_columns = TRUE)
```

سپس با دستور `data <- cor(df)` ماتریس correlation را برای این داده ها به دست می آوریم.

برای درک بهتر این ماتریس میتوانیم از نمودار زیر استفاده کنیم.

```
options(repr.plot.width = 8, repr.plot.height = 8)
data <- cor(df)

# Build a Pannel of 100 colors with Rcolor Brewer
my_colors <- brewer.pal(5, "Spectral")
my_colors <- colorRampPalette(my_colors)(100)

# Order the correlation matrix
ord <- order(data[1, ])
data_ord <- data[ord, ord]
plotcorr(data_ord , col=my_colors[data_ord*50+50] , mar=c(0,0,0,0))
```

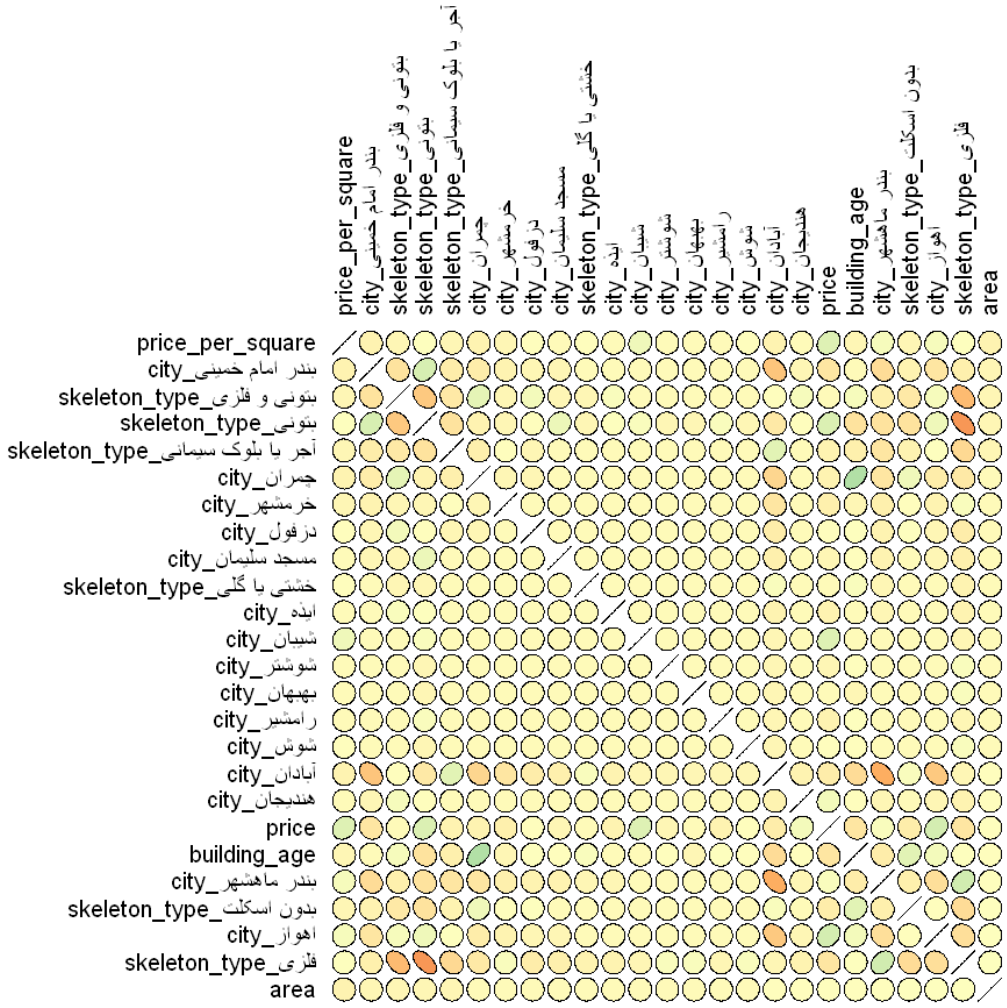

در این نمودار هر چه رنگ بیضی مربوطه به سبز نزدیک تر باشد دو متغیر رابطه مستقیم قوی تری دارند و هر چه به رنگ قرمز نزدیک تر باشد دو متغیر رابطه معکوس قوی تری دارند و بخش هایی که رنگ آن به زرد نزدیک است یعنی دو متغیر هیچ رابطه ای با یکدیگر ندارند.

برای مشاهده دقیق تر اعداد شاخص همبستگی میتوانیم از نمودار زیر نیز استفاده کنیم.

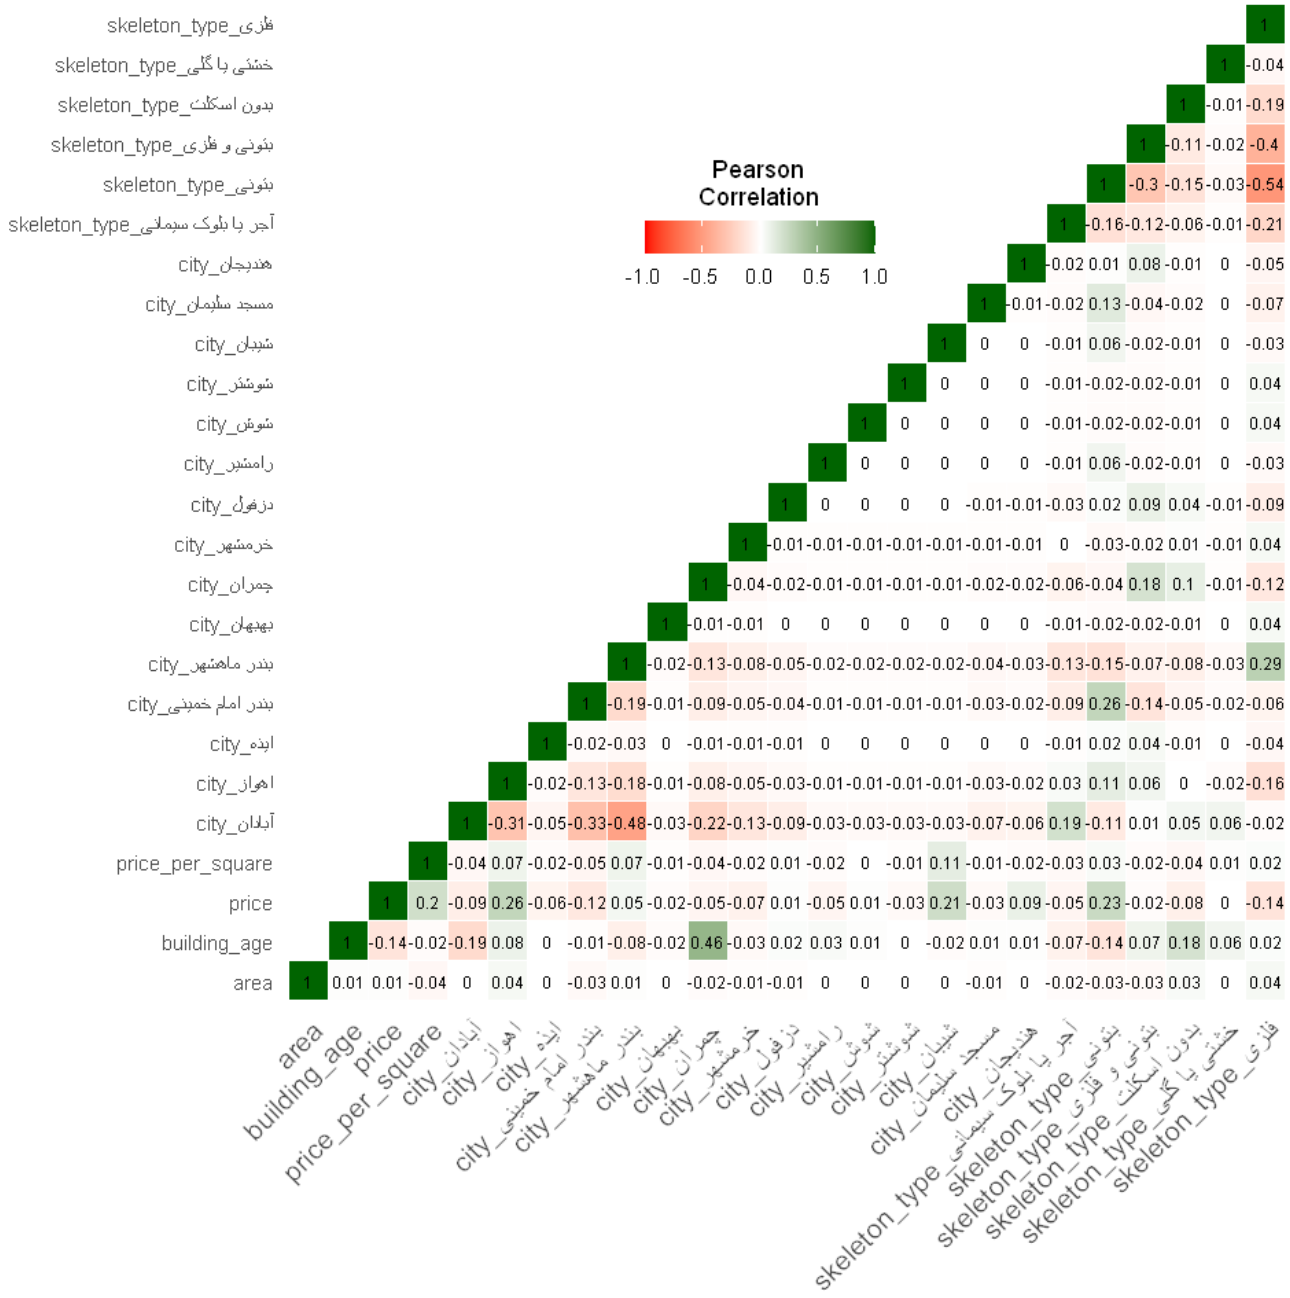

حالا نمودار جعبه ای قیمت ساختمان در شهرستان های مختلف را با دستور زیر رسم میکنیم.

```
options(repr.plot.width = 8, repr.plot.height = 3)
ggplot(khoozestan, aes(x=price, y=reorder(city, price, FUN=median) , fill=city)) +
    geom_boxplot(outlier.colour="red", outlier.shape=16,outlier.size=1) +
    labs(title="نمودار جعبه ای قیمت ساختمان در هر شهرستان", x="قیمت هر ساختمان به میلیون تومان", y = "نام شهرستان") +
    theme(legend.position="none", plot.title = element_text(hjust = 0.5))
```

همبستگی و نمودار پراکنش و نمودار توضیع داده های استان خوزستان قبل از تبدیل متغیر های رسته ای به dummy_variable به شکل زیر میباشد.

```
pairs.panels(khoozestan)
```

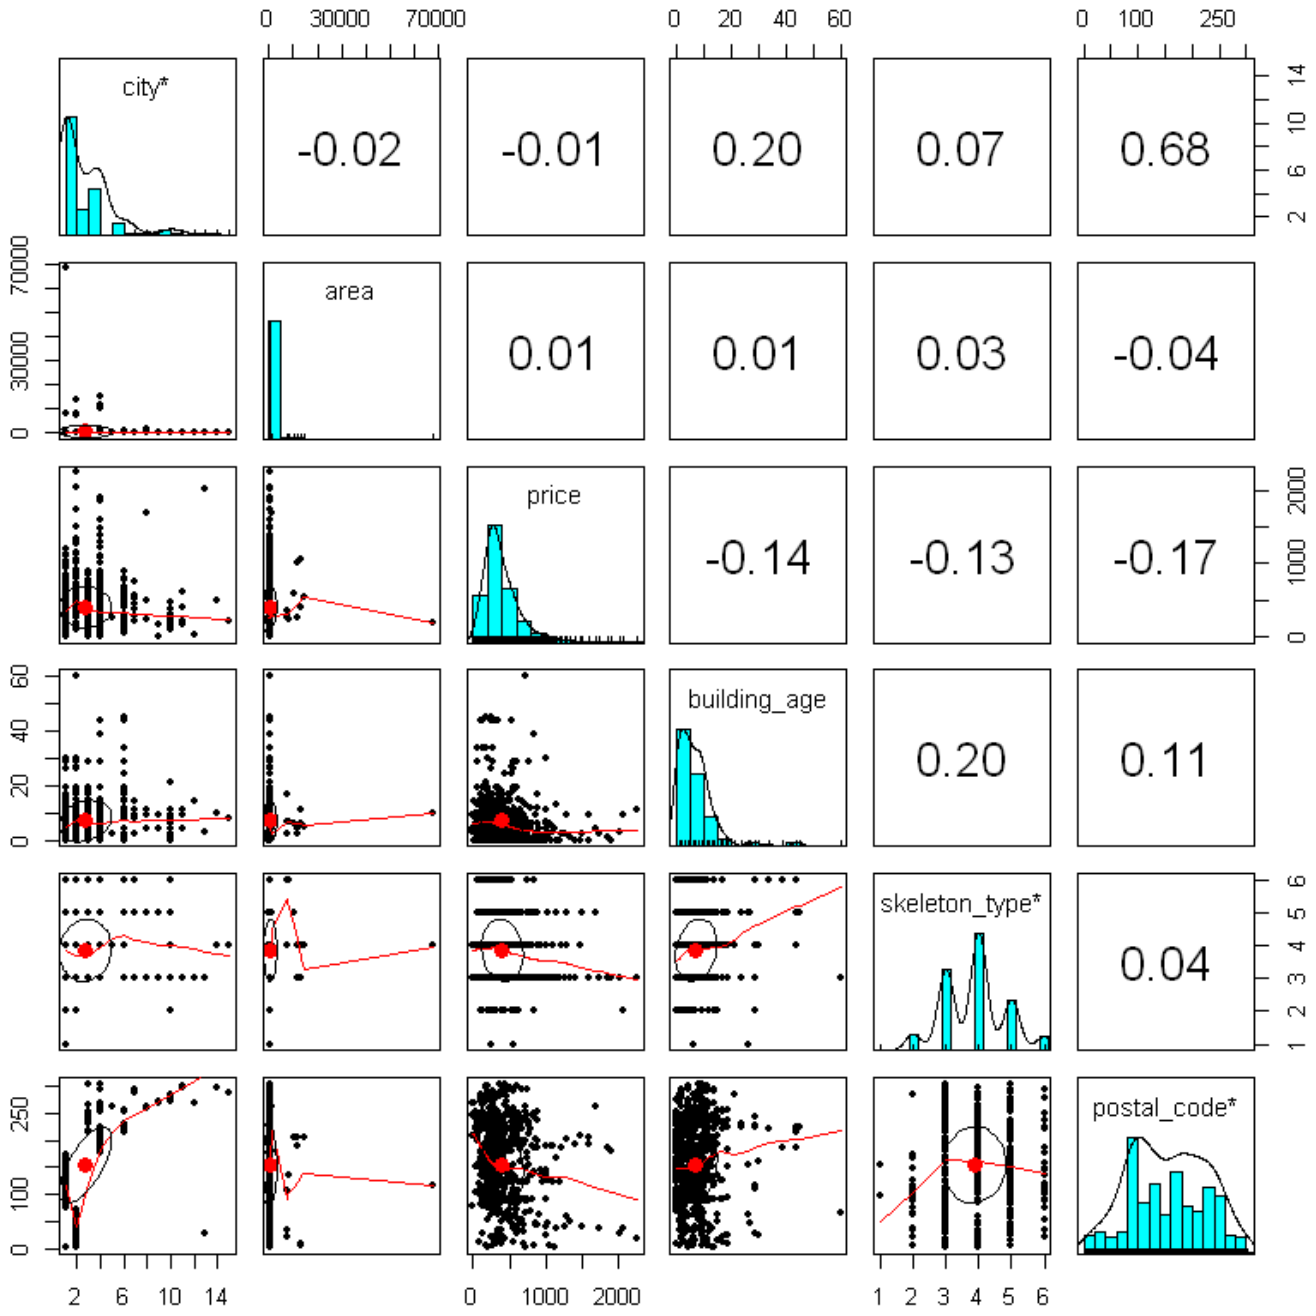

و شهرستان ها را به ترتیب میانه قیمت در نمودار نمایش میدهیم.

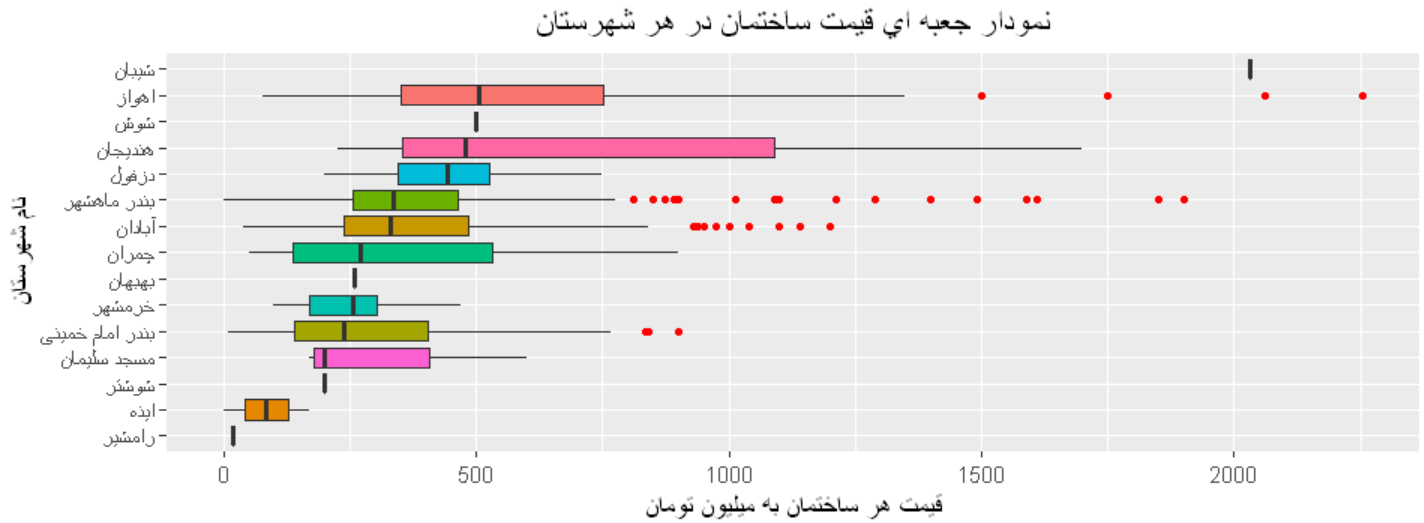

سپس همین کار را با قیمت هر متر مربع نیز انجام میدهیم.

```
options(repr.plot.width = 8, repr.plot.height = 3)
ggplot(khoozestan, aes(x=price_per_square, y=reorder(city, price_per_square, FUN=median) , fill=city)) +
geom_boxplot(outlier.colour="red", outlier.shape=16,outlier.size=1) +
labs(title="نمودار جعبه ای قیمت هر متر ساختمان در شهرستان ها قبل از کنار گذاشتن داده های پرت", x="قیمت هر متر مربع ساختمان به میلیون تومان", y = "نام شهرستان") +
geom_segment(aes(x = 200, y = 7, xend = 222, yend = 9.5),size = 1,arrow = arrow(length = unit(.3, "cm"))) +
geom_segment(aes(x = 70, y = 7, xend = 53, yend = 10.5),size = 1,arrow = arrow(length = unit(.3, "cm"))) +
theme(legend.position="none",plot.title = element_text(hjust = 0.5))
```

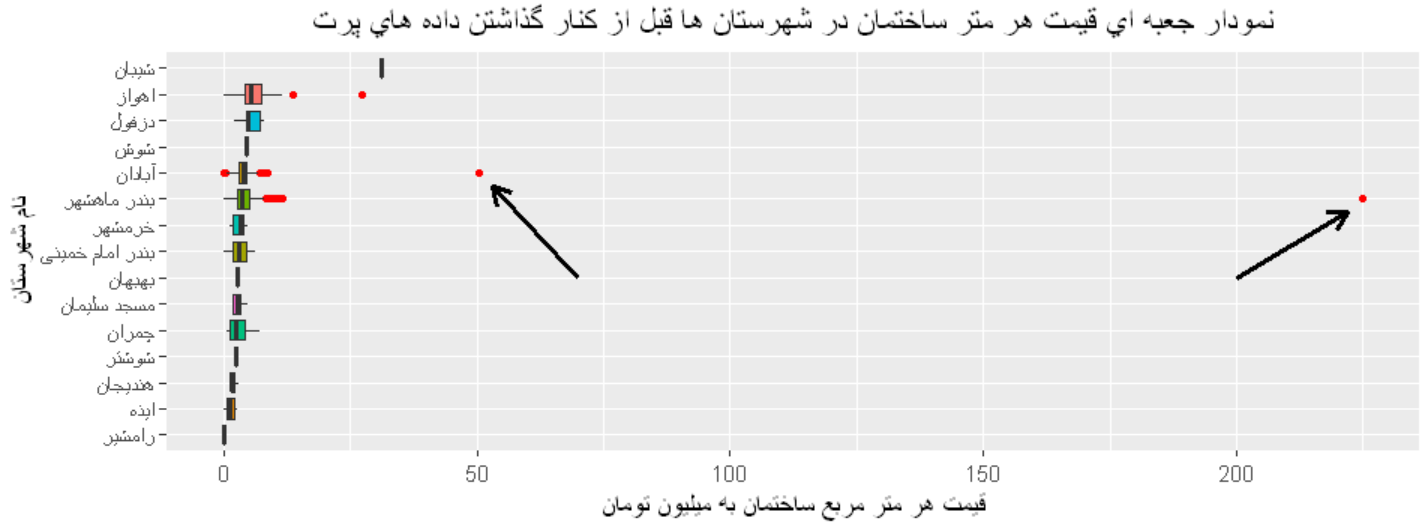

همان طور که مشاهده میکنید وجود این دو داده ی پرت باعث میشود نتوانیم به خوبی اطلاعات بقیه داده ها را مشاهده و بررسی کنیم به همین دلیل موقتا این دو داده را از اطلاعاتمان کنار میگذاریم اما مشخصات مربوط به آن ها را حذف نمیکنیم تا بتوانیم در صورت نیاز به دقت این داده ها را بررسی کنیم، لازم به ذکر است که قصد ما از حذف کردن این داده ها غلط نشان دادن آن ها و یا بی اهمیت نشان دادنشان نیست و فقط برای درک بهتر بقیه داده ها این کار را انجام میدهیم.

کد قرار داد در این دو داده ۱۹۱۸۹۱۹۸ و ۱۹۲۳۶۳۰۳ بود.

مجددا این نمودار را رسم میکنیم.

به این شکل میتوانیم دقیق تر این داده ها را بررسی کنیم.

مشکلی که در این جا ماوجه آن میشویم که در نمودار قبلی قطعا نمیتوانستیم متوجه آن شویم این است که تعداد داده ها در بعضی از شهرستان ها بسیار کم است و این موضوع سطح اطمینان ما به این داده ها را کم میکند. شهرستان هایی مانند شیبان ، شوش ، شوشتر ، بهبهان و رامشیر.

برای بررسی دقیق تر این موضوع ابتدا تعداد داده های مربوط به هر شهرستان را شمارش میکنیم.

```
confidence_level <- khoozestan %>%
    select(city) %>%
    group_by(city) %>%
    count() %>%
    arrange(n)
```

city	n
بهبهان	1
رامشير	1
شوش	1
شوشتر	1
شيبان	1
ايذه	2
هنديجان	3
مسجد سليمان	5
دزفول	8
خرمشهر	16
چمران	43
اهواز	80
بندر امام خميني	92
بندر ماهشهر	166
آبادان	346

برای درک بهتر این موضوع این اعداد را در یک نمودار میله ای نمایش میدهیم. هر چه تعداد داده های مربوط به یک شهرستان بیشتر باشد، سطح اطمینان ما به شاخص های آماری مربوط به آن شهرستان نیز افزایش پیدا میکند.

```
options(repr.plot.width = 7, repr.plot.height = 5)
ggplot(confidence_level , aes(x=n , y=reorder(city,n), fill = n)) +
    geom_bar(stat = "identity") +
    labs(title="سطح اطمینان شاخص های آماری در هر شهرستان", x="تعداد", y = "نام شهرستان") +
    scale_fill_gradient(name = "تعداد داده ها",low="black", high="#22b14d") +
    theme(plot.title = element_text(hjust = 0.5))
```

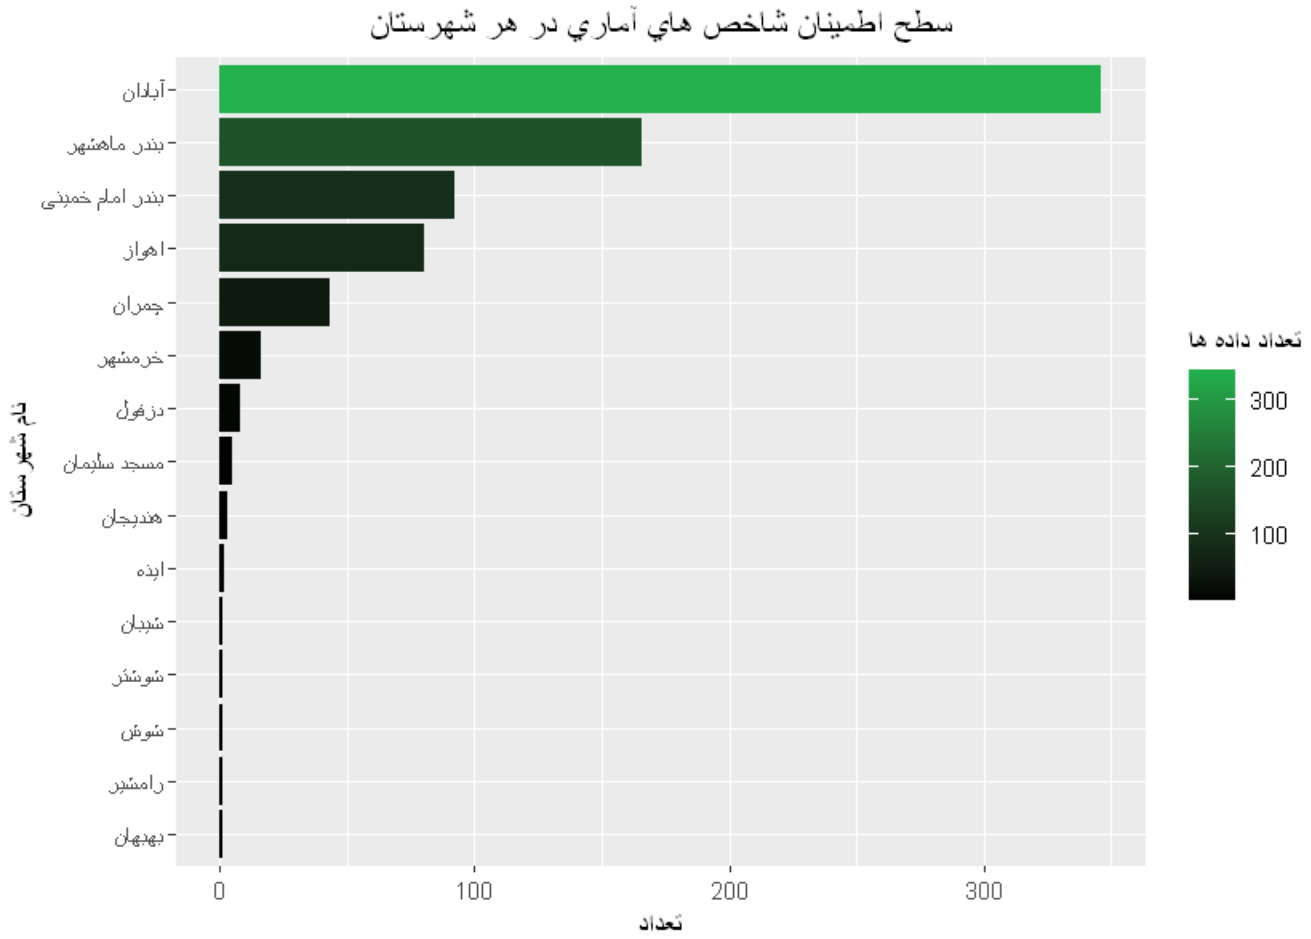

همان طور که مشاهده میکنید علاوه بر بهبان ، رامشیر ، شوش ، شوشتر و شیبان ، تعداد داده های شهرستان های ایذه ، هندیجان ، مسجد سلیمان و دزفول نیز زیر ۱۰ میباشد و به همین دلیل سطح اطمینان شاخص های آماری در این داده ها بسیار پایین است و به همین دلیل داده های مربوط به این شهرستان ها را کنار میگذاریم تا بتوانیم بقیه داده ها را دقیق تر بررسی کنیم.

مجددا بر این نکته تاکید میکنم که تمام این داده ها برای ما مهم هستند و باید اطلاعات هر یک مورد بررسی قرار گیرد.

سطح اطمینان شاخص هاي آماري در هر شهرستان پس از کنار گذاشتن شهرستان ها با تعداد داده هاي زير 10

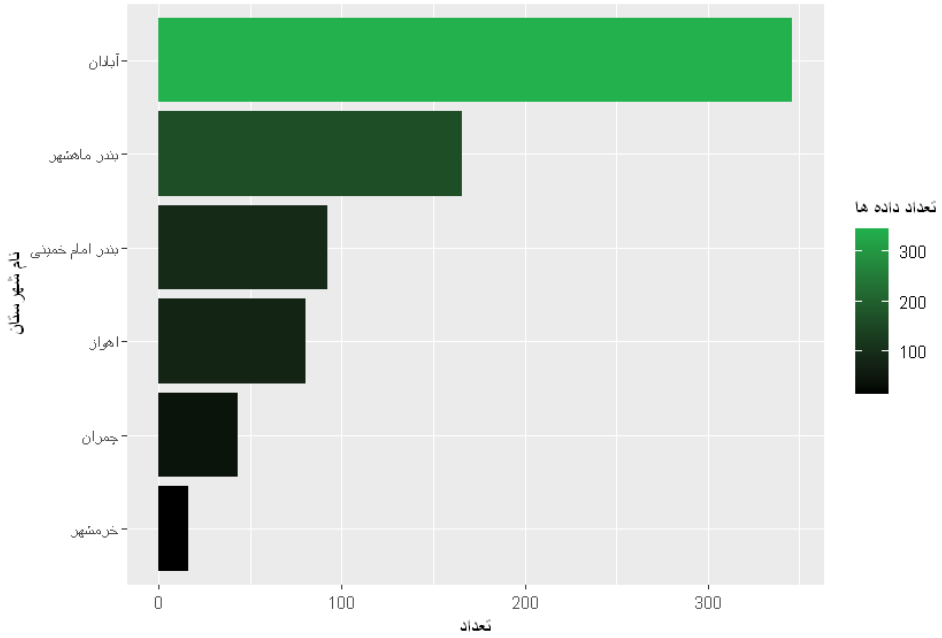

همچنین برای این کار میتوانیم از نمودار Treemap استفاده کنیم.

```
options(repr.plot.width = 5, repr.plot.height = 5)
ggplot(confidence_level, aes(area = n, fill = n,label = city)) +
    geom_treemap() +
    geom_treemap_text(colour = "white",size = 15, place = "centre",grow = FALSE) +
    labs(title="تعداد داده ها در هر شهرستان") +
    scale_fill_gradient(name = "تعداد داده ها",low="black", high="#22b14d") +
    theme(legend.position="none",plot.title = element_text(hjust = 0.5))
```

برای مقایسه میانگین قیمت بین این چند شهرستان از نمودار میله ای استفاده میکنیم.

city	mean_price
اهواز	623.4250
آبادان	378.0111
بندر امام خمینی	309.6426
بندر ماهشهر	431.9117
چمران	344.5581
خرمشهر	259.9812

```
df <- khoozestan %>%
    select(city,price) %>%
    group_by(city) %>%
    summarise(mean_price = mean(price))
df
```

```
options(repr.plot.width = 8, repr.plot.height = 3.1)
confidence = confidence_level[match(reorder(df$city , df$mean_price), confidence_level$city),]$n
ggplot(df , aes(x=mean_price , y=reorder(city,mean_price),fill = confidence)) +
    geom_bar(stat = "identity") +
    labs(title="میانگین قیمت هر شهرستان", x="میانگین قیمت به میلیون تومان", y = "نام شهرستان") +
    scale_fill_gradient(name='سطح اطمینان',low="black", high="#22b14d") +
    theme(plot.title = element_text(hjust = 0.5))
```

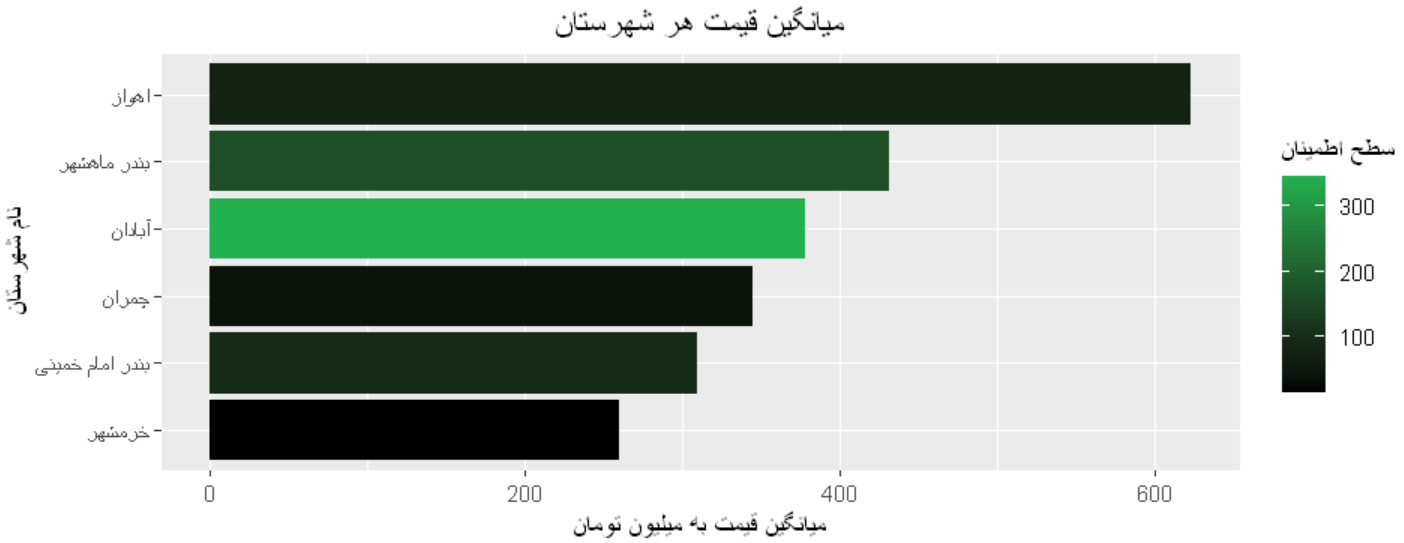

همین نمودار را برای اطلاعات مربوط به قیمت هر متر مربع نیز رسم میکنیم.

city	mean_price_per_square
اهواز	6.002169
آبادان	3.839624
بندر امام خمینی	3.195575
بندر ماهشهر	4.127006
چمران	2.949167
خرمشهر	3.095103

```
df <- khoozestan %>%
    select(city,price_per_square) %>%
    group_by(city) %>%
    summarise(mean_price_per_square = mean(price_per_square))
df
```

```
options(repr.plot.width = 8, repr.plot.height = 3.1)
confidence = confidence_level[match(reorder(df$city , df$mean_price_per_square), confidence_level$city),]$n
ggplot(df , aes(x=mean_price_per_square , y=reorder(city,mean_price_per_square),fill = confidence)) +
    geom_bar(stat = "identity") +
    labs(title="میانگین قیمت هر متر مربع ساختمان در هر شهرستان", x="میانگین قیمت هر متر مربع ساختمان به میلیون تومان", y = "نام شهرستان") +
    scale_fill_gradient(name='سطح اطمینان',low="black", high="#22b14d") +
    theme(plot.title = element_text(hjust = 0.5))
```

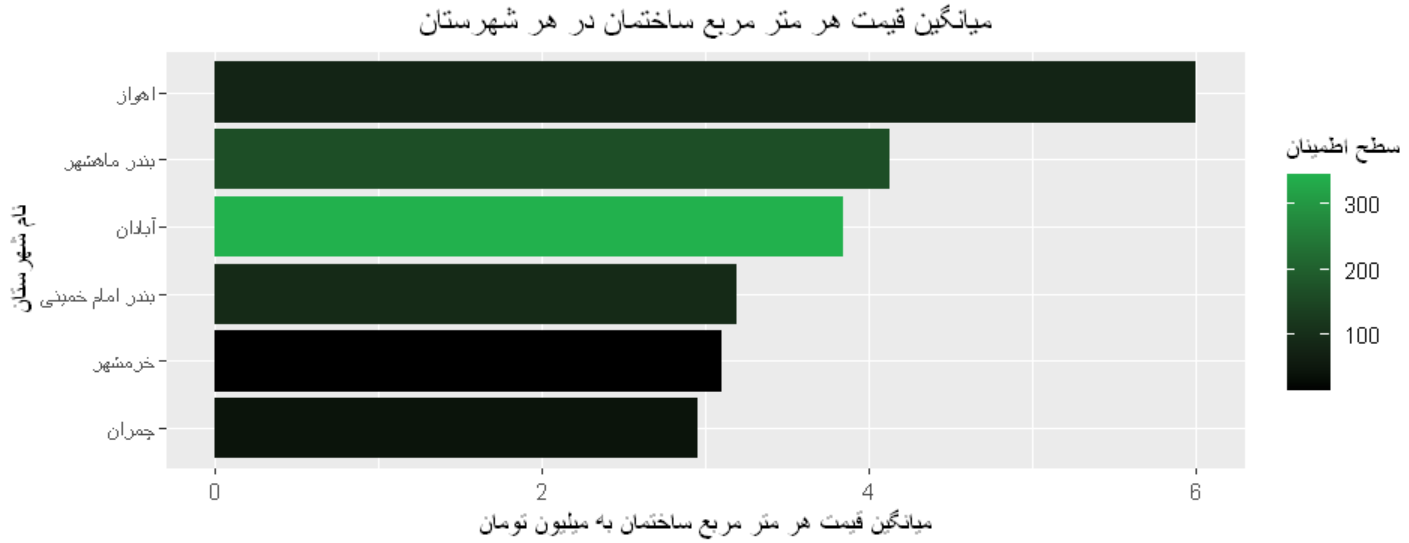

پراکندگی داده ها در هر یک شهرستان ها بر اساس قیمت هر متر مربع ساختمان به شکل زیر است.

```
options(repr.plot.width = 6, repr.plot.height = 3)
ggplot(khoozestan, aes(x = price_per_square, y = reorder(city, price_per_square, FUN=median), fill = city)) +
  geom_density_ridges_gradient(scale = 1, rel_min_height = 0.01) +
    labs(title="نمودار پراکندگی داده های هر کدام از شهرستان ها بر اساس قیمت هر متر مربع", x="قیمت هر متر مربع به میلیون تومان", y = "نام شهرستان") +
    theme(legend.position="none",plot.title = element_text(hjust = 0.5))
```

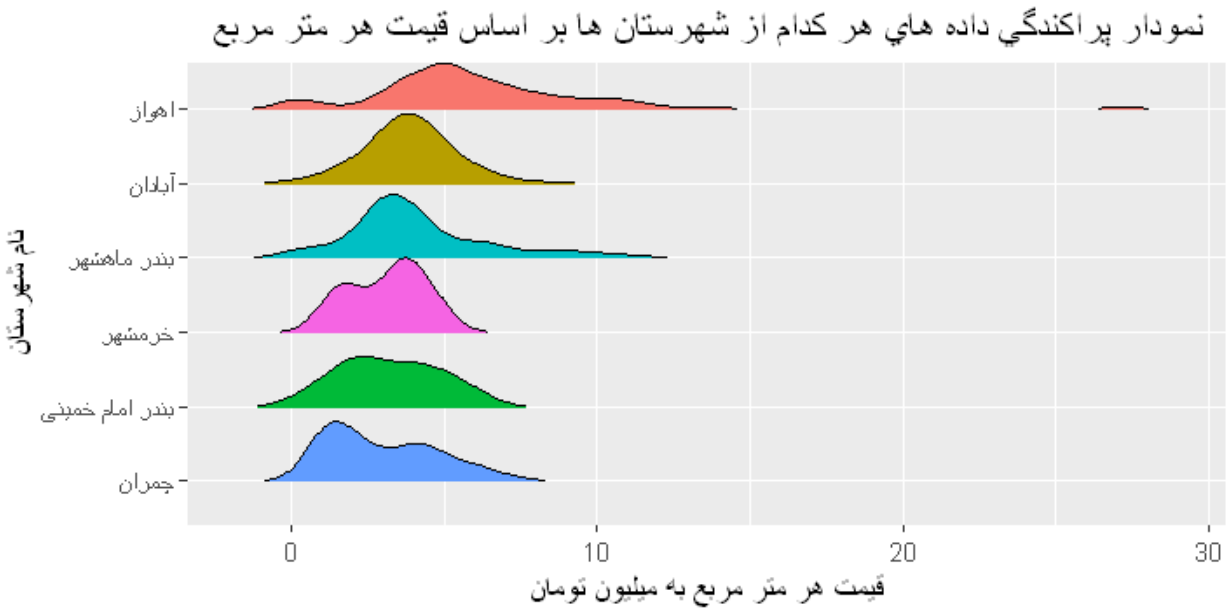

میتوان تعداد داده های موجود در هر قیمت را به کمک دستور geom_count روی نمودار جعبه ای نشان داد که در نمودار زیر میتوانید آن را مشاهده کنید.

```
options(repr.plot.width = 8, repr.plot.height = 3)
ggplot(khoozestan, aes(x=price, y=reorder(city, price, FUN=median) , fill=city)) +
    geom_boxplot(outlier.colour="red", outlier.shape=16,outlier.size=1) +
    geom_count(col="black", show.legend=F)+
    labs(title="نمودار جعبه ای قیمت ساختمان در هر شهرستان", x="قیمت هر ساختمان به میلیون تومان", y = "نام شهرستان") +
    theme(legend.position="none",plot.title = element_text(hjust = 0.5))
```

نمونه ی دیگری از همین نمودار برای قیمت هر متر مربع را میتوانیم به شکل زیر رسم کنیم.

```
options(repr.plot.width = 8, repr.plot.height = 3)
ggplot(khoozestan, aes(x=price_per_square, y=reorder(city, price_per_square, FUN=median) , fill=city)) +
    geom_boxplot(outlier.colour="red", outlier.shape=16,outlier.size=1) +
    geom_count(col="black", show.legend=F)+
    labs(title="نمودار جعبه ای قیمت هر متر مربع ساختمان در شهرستان ها", x="قیمت هر متر مربع ساختمان به میلیون تومان", y = "نام شهرستان") +
    theme(legend.position="none",plot.title = element_text(hjust = 0.5))
```

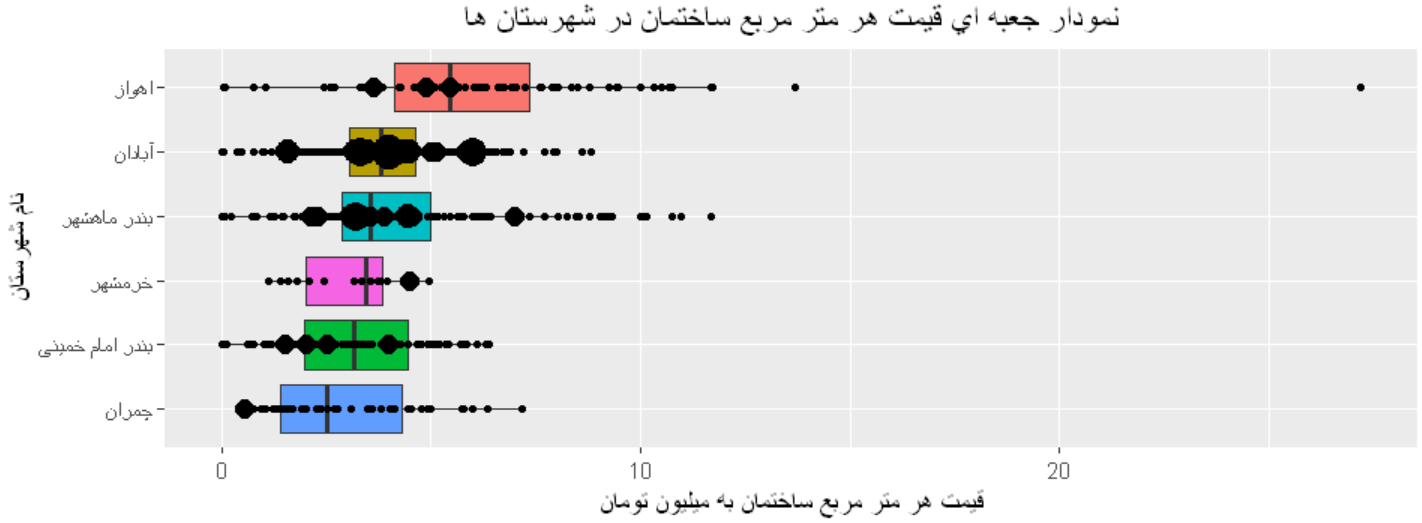

حالا قصد داریم تاثیر اسکلت ساختمان بر قیمت بنا را بررسی کنیم.

نمودار اولی که برای این منظور رسم میکنیم که نمودار پراکندگی قیمت ساختمان ها بر اساس قیمت آن ها میباشد.

```
options(repr.plot.width = 8, repr.plot.height = 3.5)
ggplot(khoozestan[khoozestan$price < quantile(khoozestan$price,0.9),], aes(price)) +
#     geom_histogram(aes(fill=skeleton_type), binwidth = 100,col='black', size=.1) +
    geom_histogram(aes(fill=skeleton_type), bins=100, col="black", size=.1) +
    labs(title="نمودار بافت نگار قیمت (9 دهک اول) ساختمان ها قیمت به تفکیک نوع اسکلت ساختمان", x="قیمت هر ساختمان به میلیون تومان", y = "تعداد")+
    theme(plot.title = element_text(hjust = 0.5))
```

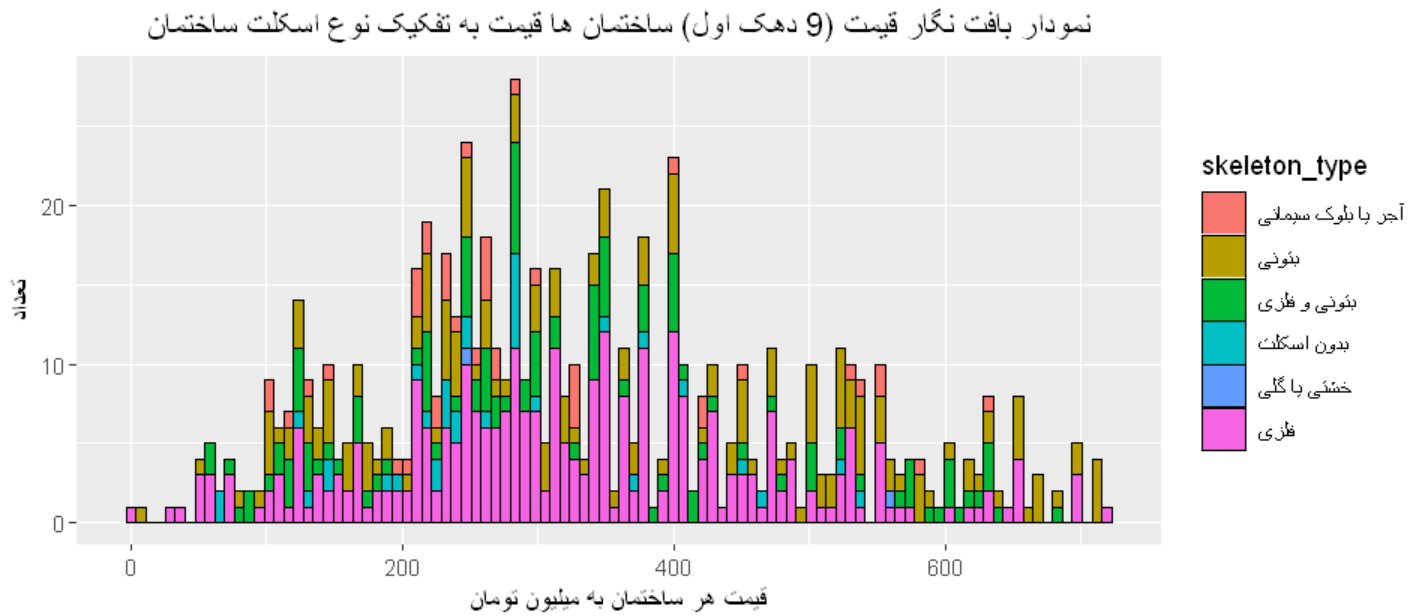

و سپس همین نمودار را برای قیمت هر متر مربع رسم میکنیم.

```
options(repr.plot.width = 8, repr.plot.height = 3.5)
ggplot(khoozestan[khoozestan$price_per_square < quantile(khoozestan$price_per_square,0.9),], aes(price_per_square)) +
    geom_histogram(aes(fill=skeleton_type), binwidth = 0.1,col='black', size=.1) +
#     geom_histogram(aes(fill=skeleton_type), bins=100, col="black", size=.1) +
    labs(title="نمودار بافت نگار قیمت هر متر مربع (9 دهک اول) ساختمان به تفکیک نوع اسکلت ساختمان", x="قیمت هر متر مربع ساختمان به میلیون تومان", y = "تعداد")+
    theme(plot.title = element_text(hjust = 0.5))
```

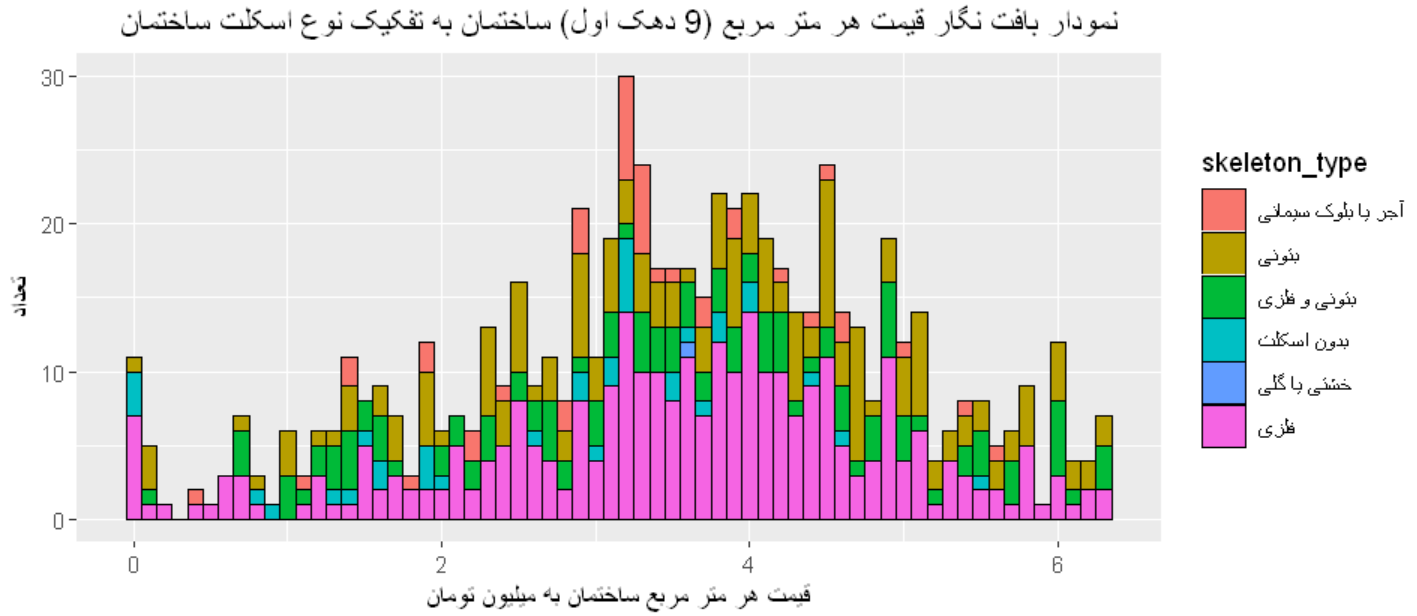

در این دو نمودار برای درک بهتر از داده ها تنها ۹ دهک اول داده در آن متغیر (قیمت یا قیمت هر متر مربع) را رسم کرده ایم.

در نمودار اول کل ۹ دهک اول را به ۱۰۰ بازه از قیمت تقسیم کرده ایم و تعداد داده های مربوط به هر نوع از اسکلت ها را در آن نشان داده ایم.

این کار را با قرار دادن مقدار bins برابر با ۱۰۰ انجام داده ایم.

در نمودار دوم کل ۹ دهک اول را به ازای هر ۱۰۰ هزار تومن یک بازه جدید ایجاد کرده ایم و تعداد داده های مربوط به هر نوع از اسکلت ها را در آن نشان داده ایم.

این کار را با قرار دادن مقدار binwidth برابر با ۰.۱ انجام داده ایم چون واحد ما در این داده ها میلیون تومان است پس ۰.۱ آن برابر با ۱۰۰ هزار تومان است.

نمودار بعدی که رسم میکنیم نمودار جعبه ای قیمت شهرستان ها به تفکیک نوع اسکلت در آن ها میباشد.

```
options(repr.plot.width = 8, repr.plot.height = 3.5)
ggplot(khoozestan, aes(x=city, y=price , fill = skeleton_type)) +
    geom_boxplot(aes(colour = skeleton_type) ,outlier.colour="black", outlier.shape=21,outlier.size=1) +
    labs(title="نمودار جعبه ای قیمت هر ساختمان در هر شهرستان به تفکیک نوع اسکلت", y="قیمت هر ساختمان به میلیون تومان", x = "نام شهرستان") +
    theme(plot.title = element_text(hjust = 0.5))
```

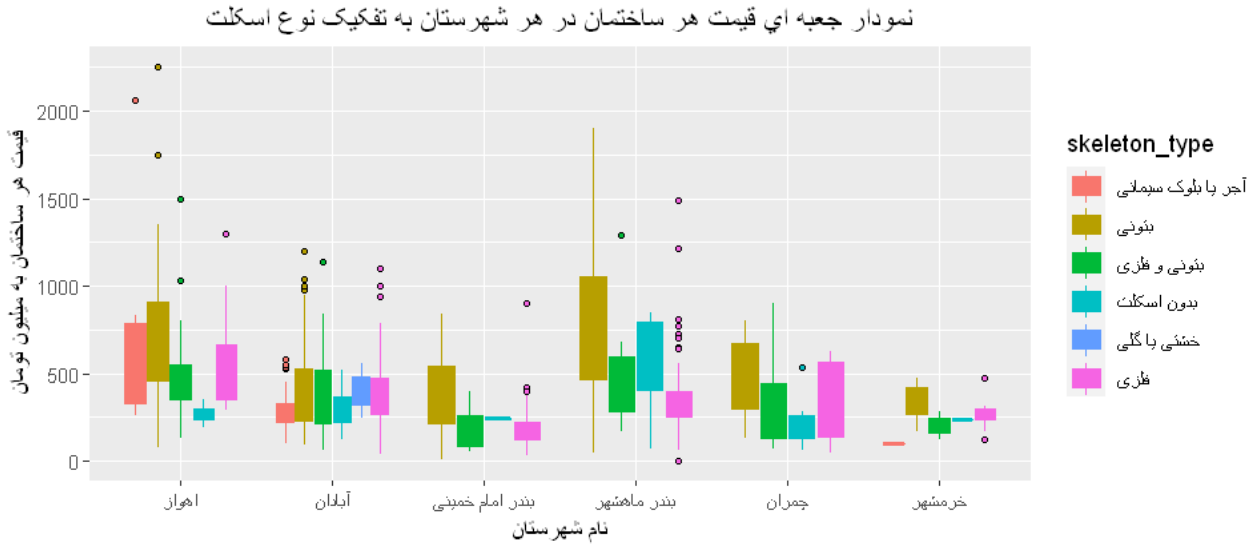

و سپس این نمودار را برای قیمت هر متر مربع ساختمان نیز رسم میکنیم.

```
options(repr.plot.width = 8, repr.plot.height = 3.5)
ggplot(khoozestan, aes(x=city, y=price , fill = skeleton_type)) +
    geom_boxplot(aes(colour = skeleton_type) ,outlier.colour="black", outlier.shape=21,outlier.size=1) +
    labs(title="نمودار جعبه ای قیمت هر ساختمان در هر شهرستان به تفکیک نوع اسکلت", y="قیمت هر ساختمان به میلیون تومان", x = "نام شهرستان") +
    theme(plot.title = element_text(hjust = 0.5))
```

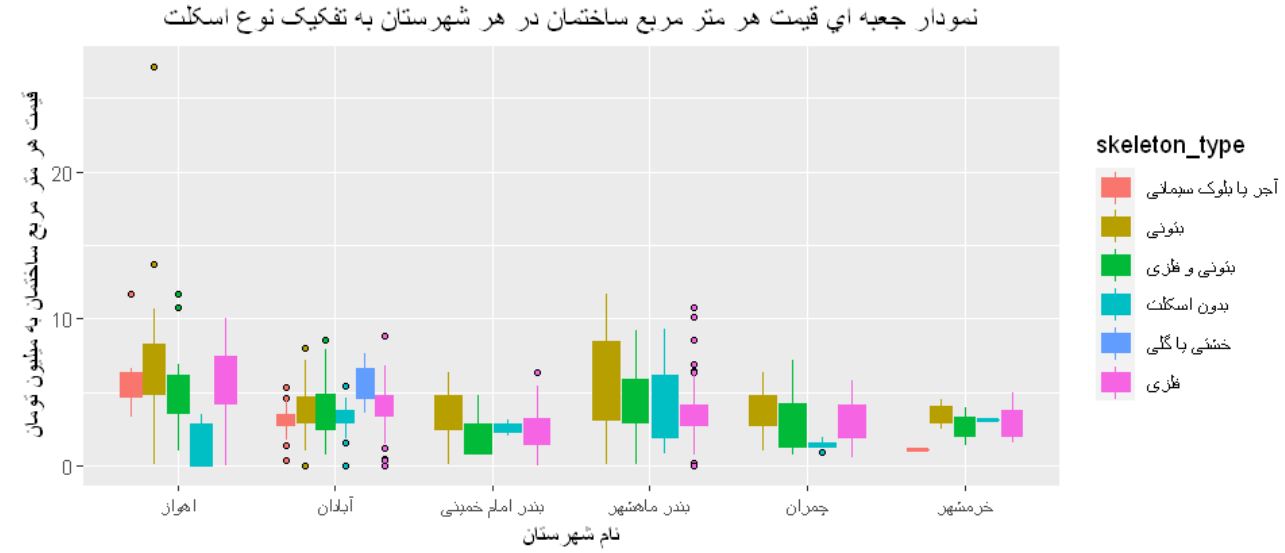

برای بررسی تاثیر سن ساختمان روی قیمت ساختمان نمودار پراکنشی داده های این دو ستون را به تفکیک شهرستان رسم میکنیم.

```
options(repr.plot.width = 8, repr.plot.height = 5)
ggplot(khoozestan[khoozestan$price < quantile(khoozestan$price,0.9),], aes(x=building_age, y=price , color = city)) +
    geom_point(size=1,alpha=0.5) +
    labs(title="نمودار پراکنش قیمت (9 دهک اول) هر ساختمان بر اساس سن ساختمان به تفکیک شهرستان", x="سن ساختمان", y = "قیمت هر ساختمان به میلیون تومان") +
    theme(plot.title = element_text(hjust = 0.5))
```

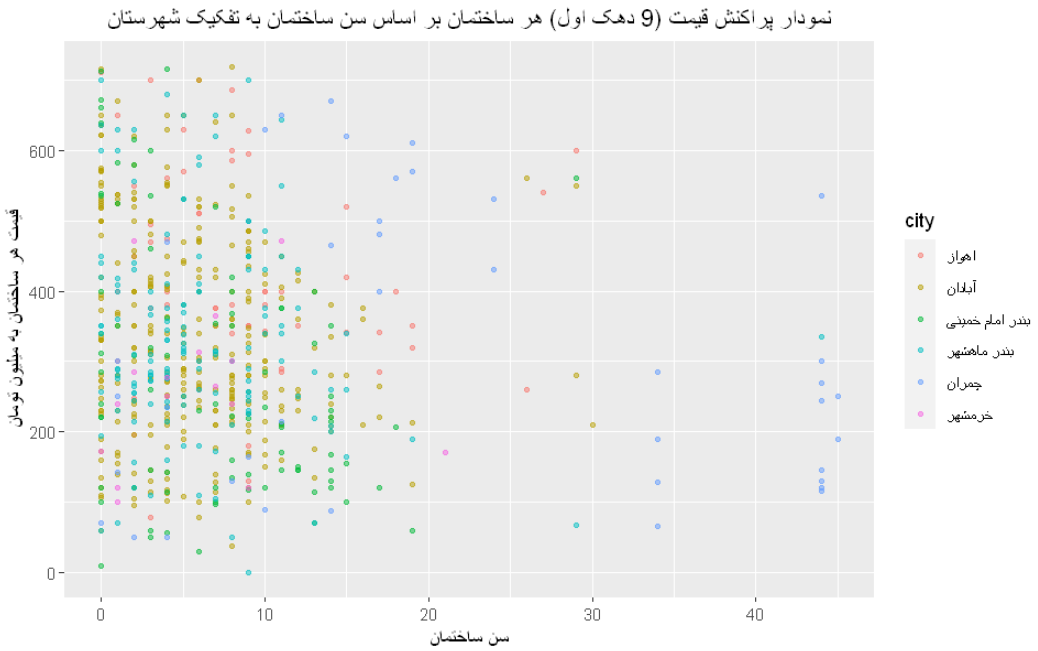

و سپس این نمودار را برای قیمت هر متر مربع نیز رسم میکنیم.

```
options(repr.plot.width = 8, repr.plot.height = 5)
ggplot(khoozestan[khoozestan$price_per_square < quantile(khoozestan$price_per_square,0.9),],
    aes(x=building_age, y=price_per_square , color = city)) +
    geom_point(size=1,alpha=0.5) +
    labs(title="نمودار پراکنش قیمت هر متر مربع (9 دهک اول) ساختمان بر اساس سن ساختمان به تفکیک شهرستان",
    x="سن ساختمان", y ="قیمت هر متر مربع ساختمان به میلیون تومان") +
    theme(plot.title = element_text(hjust = 0.5))
```

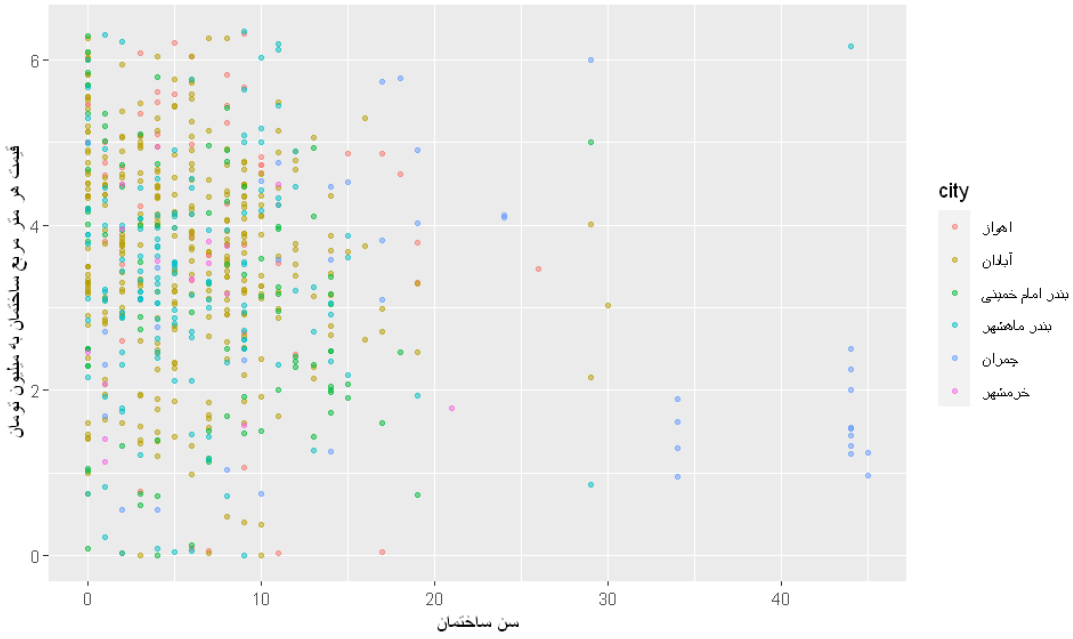

سپس برای بررسی تاثیر مساحت روی قیمت ساختمان نمودار زیر را رسم میکنیم.

```
options(repr.plot.width = 8, repr.plot.height = 5)
ggplot(khoozestan, aes(x=area, y=price , color = city)) +
    geom_point(size=1,alpha=0.4,) +
    labs(title="نمودار قیمت بر اساس مساحت ساختمان به تفکیک شهرستان", y=" قیمت هر ساختمان", x = "مساحت")+
    theme(plot.title = element_text(hjust = 0.5))
```

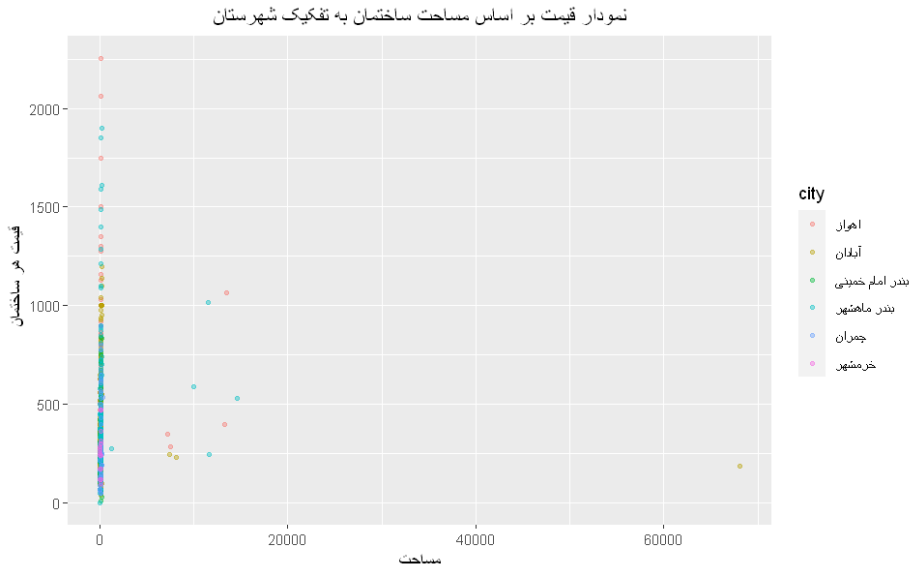

همان طور که مشاهده میکنید در این جا نیز به دلیل وجود داده های پرت و ساختمان هایی با مساحت های بسیار بالا بررسی بخش عمده ای از داده ها عملا غیر ممکن شده است بنابراین در این جا نیز تنها ۹ دهک اول داده ها را بررسی میکنم. در تمام بخش های این گزارش که تنها ۹ دهک از داده ها نمایش داده شده است به همین دلیل است که در غیر این صورت مصور سازی این داده ها نمیتوانست هیچ اطلاعاتی در اختیار ما قرار دهد.

```
options(repr.plot.width = 8, repr.plot.height = 5)
ggplot(khoozestan[(khoozestan$area < quantile(khoozestan$area,0.90))&(khoozestan$price < quantile(khoozestan$price,0.9)),],
    aes(y=price, x=area , color = city)) +
    geom_point(size=1,alpha=0.4,) +
    labs(title="نمودار قیمت (9 دهک اول) بر اساس مساحت (9 دهک اول) ساختمان به تفکیک شهرستان", y=" قیمت هر ساختمان", x = "مساحت")+
    theme(plot.title = element_text(hjust = 0.5))
```

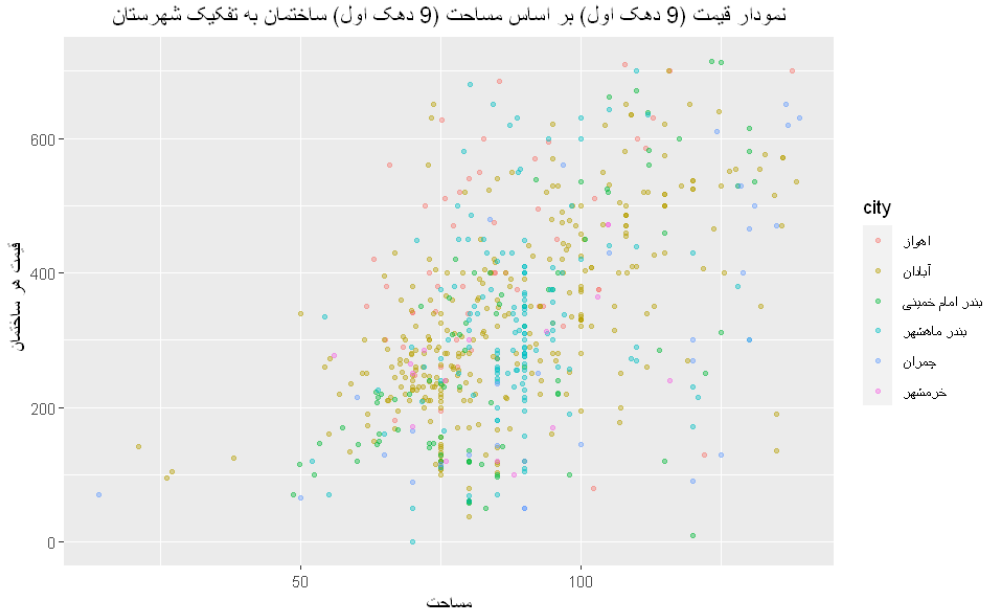

سپس همین نمودار را برای قیمت هر متر مربع نیز رسم میکنیم.

```
options(repr.plot.width = 8, repr.plot.height = 5)
ggplot(khoozestan[(khoozestan$area < quantile(khoozestan$area,0.90))&
    (khoozestan$price_per_square < quantile(khoozestan$price_per_square,0.9)),],
    aes(y=price_per_square, x=area , color = city)) +
    geom_point(size=1,alpha=0.4,) +
    labs(title="نمودار قیمت هر متر مربع (9 دهک اول) بر اساس مساحت (9 دهک اول) ساختمان به تفکیک شهرستان", y="قیمت هر متر مربع", x = "مساحت")
```

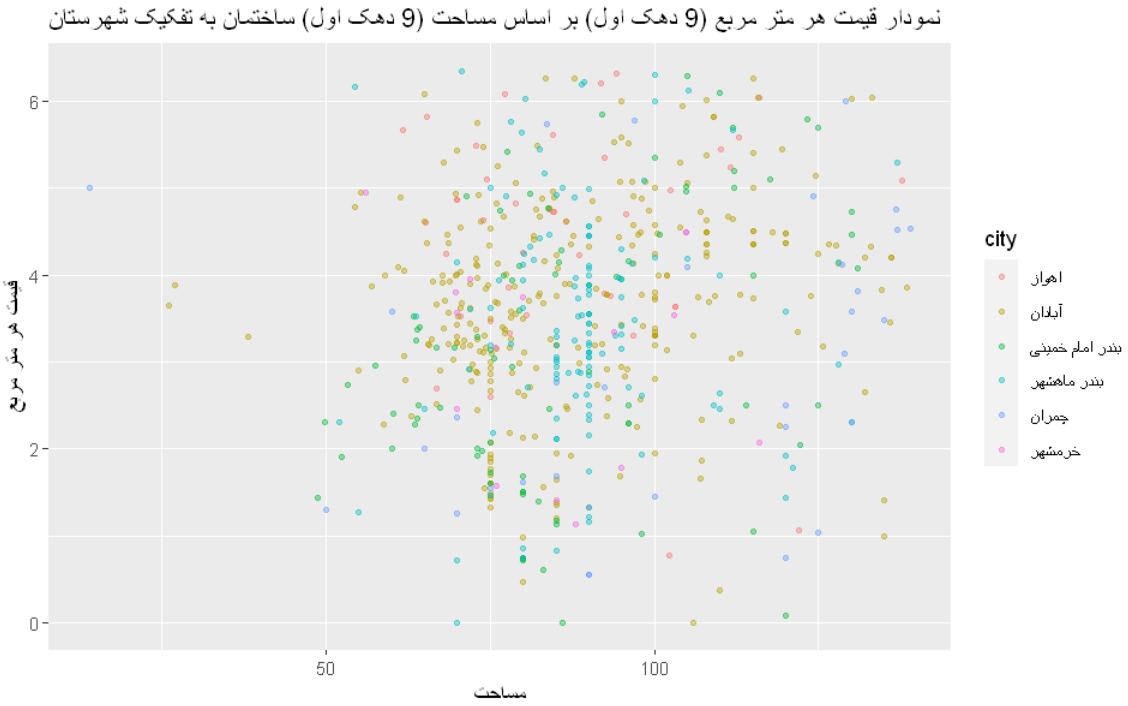

بررسی مدل های پیشگو روی داده ها

1. **رگرسیون**
   - ۱,۱ **رگرسیون با تمام متغیر های پیشگو**
   - ۱,۲ **رگرسیون قدم به قدم پیشرو**
   - ۱,۳ **رگرسیون قدم به قدم پسرو**
   - ۱,٤ **رگرسیون قدم به قدم دوسویه**
   - ۱,٥ **رگرسیون فرسا**

2. **K-نزدیک ترین همسایه**

3. **درخت های پیشگو**
   - ۳,۱ **درخت پیشگو بدون تنظیم کردن پارامتر ها**
   - ۳,۲ **عمیق ترین درخت پیشگو**
   - ۳,۳ **عمیق ترین درخت پیشگو (هرس شده با کمترین xerror)**
   - ۳,٤ **عمیق ترین درخت پیشگو (بهترین هرس)**
   - ۳,٥ **جنگل تصادفی**
   - ۳,٦ **درخت تقویت شده**

4. **شبکه های عصبی مصنوعی**

۱. رگرسیون

برای پیاده سازی مدل های پیشبینی ابتدا باید داده های مورد نیازمان را به درستی آماده کنیم تا بتوانیم عملکرد مدل های مختلف را به درستی روی آن بررسی کنیم چون اگر ما داده های نامناسب به هر مدل یادگیری بدهیم آن مدل نتیجه خوبی به ما نخواهد داد و یکی از مهم ترین بخش های آموزش مدل های مختلف پیش پردازش داده ها متناسب با ویژگی های آن مدل است.

در بخش تصویری سازی ستون های مختلف داده ها را معرفی کردیم و اطلاعات آن ها را نمایش دادیم.

همان طور که گفته شد برخی ستون های این داده ها هیچ اطلاعاتی در اختیار ما قرار نمیدهند یا اگر هم قرار میدهند اطلاعاتی است که جنبه پیشگویانه ندارد و ما نمیتوانیم از این اطلاعات در مدل هایمان استفاده کنیم پس مانند بخش تصویری سازی این ستون ها را حذف میکنیم

پس از انجام مراحل ابتدایی داده های ما به شکل زیر در می آید.

city	area	price	building_age	skeleton_type	postal_code
اهواز	75.00	195	2	بدون اسکلت	617563
اهواز	96.30	735	13	فلزي	191181
اهواز	111.60	585	8	بتوني	618493
اهواز	13313.00	400	11	فلزي	613668
اهواز	80.48	285	11	بتوني و فلزي	613495
اهواز	72.22	500	9	بتوني و فلزي	617763

از آن جا که برخی از توابع زبان R با زبان فارسی مشکل دارند در همین ابتدای کار اطلاعات دو ستون city و skeleton_type را به صورت انگلیسی مینویسیم.

برای اینکار از تابع mapvalues که در کتابخانه plyr موجود است استفاده میکنیم.

```
city before mapping
```

'اهواز' 'ایذه' 'آبادان' 'بندر امام خمینی' 'بندر ماهشهر' 'بهبهان' 'چمران' 'خرمشهر' 'دزفول' 'رامشیر' 'شوش' 'شوشتر' 'شیبان' 'مسجد سلیمان' 'هندیجان'

```
city after mapping
```

'ahvaz' 'izeh' 'abadan' 'bandare_emam_khomeini' 'bandare_mahshahr' 'behbahan' 'chamran' 'khorramshahr' 'dezfool' 'raamshir' 'shoosh' 'shooshtar' 'shiban' 'masjed_soleiman' 'handijan'

```
skeleton_type before mapping
```

'بدون اسکلت' 'فلزی' 'بتونی' 'بتونی و فلزی' 'آجر یا بلوک سیمانی' 'خشتی یا گلی'

```
skeleton_type after mapping
```

'none' 'metal' 'concrete' 'metal_concrete' 'brick_or_cement_block' 'adobe_or_clay'

پس از این مرحله داده ما به شکل زیر در می آید.

city	area	price	building_age	skeleton_type	postal_code
ahvaz	75.00	195	2	none	617563
ahvaz	96.30	735	13	metal	191181
ahvaz	111.60	585	8	concrete	618493
ahvaz	13313.00	400	11	metal	613668
ahvaz	80.48	285	11	metal_concrete	613495
ahvaz	72.22	500	9	metal_concrete	617763

در مدل رگرسیون ما قصد داریم تا یک ترکیب خطی از متغیر های پیشگو را پیشبینی کنیم تا بوسیله آن بتوانیم متغیر برآمد داده های مورد نظرمان را از روی اطلاعاتشان پیشگویی کنیم. برای این کار نیاز است که بتوان به صورت عددی این متغیر ها را نشان داد پس باید راهی پیدا کنیم تا بتوان متغیر های رسته ای را به صورت عددی نمایش داد.

اگر متغیر رسته ای مورد نظر حالت ترتیبی داشته باشد ، مثلا متغیری که مقادیر مختلف آن "بد" "متوسط" "خوب" باشند، در این جا میتوان متغیر ها را به اعدادی ترتیبی تبدیل کرد مثلا در این جا به ۱- , ۰ , ۱ میتوان تبدیل کرد. اما اگر این متغیر ها ترتیبی نداشته باشند باید آن ها را به dummy_variable تبدیل کنیم که به آن نمایش one hot encoding نیز میگویند که به ازای هر رسته در هر متغیر رسته ای یک متغیر جدید ساخته میشود که اگر آن داده عضو آن رسته باشد مقدارش برابر ۱ و در غیر اینصورت برابر ۰ خواهد بود.

در این جا ستون city و skeleton_type متغیر های رسته ای هستند که ترتیب در آن ها معنا ندارد و باید به شکل dummy_variable تبدیل شوند.

ستون کد پستی با این که یک ستون عددی میباشد اما عدد های این ستون در واقعیت نشان دهنده محله های مختلف در شهرستان های مختلف آن استان میباشند و باید همانند ستون city آن ها را نیز به dummy_variable تبدیل کنیم. نمیتوانیم بگوییم که یک کد پستی از دیگری بزرگتر است یا این که آن ها را با هم جمع کنیم و این نشان دهنده این است که این ستون از جنس عدد نیست و از جنس رسته است و باید با آن مانند یک متغیر رسته ای عمل کرد.

ابعاد جدول داده ها بعد از این تبدیلات به شکل زیر میشود.

```
dim(dummy_khoozestan)
```

```
768  327
```

از ۰.۸ داده ها برای آموزش مدل و از ۰.۲ دیگر برای اعتبار سنجی استفاده میکنیم.

```
set.seed(831)

train_index = sample.int(nrow(dummy_khoozestan), 0.8*nrow(dummy_khoozestan), replace=F)

train = dummy_khoozestan[train_index,]
validation = dummy_khoozestan[-train_index,-c(17)]
y_validation = dummy_khoozestan[-train_index,c(17)]
```

```
dim(train)
```

```
614  327
```

```
dim(validation)
```

```
154  326
```

۱,۱ رگرسیون با تمام متغیر های پیشگو

در این بخش ابتدا یک مدل رگرسیون با تمام متغیر های پیشگو میسازیم.

```
all.reg <- lm(price ~ . ,data = train)
```

به دلیل بزرگ بودن جدول summary اطلاعات متغیر ها را در این جا نمیتوان نشان داد ، برای بررسی آن ها به کد مراجعه شود.

```
Residual standard error: 184.9 on 339 degrees of freedom
Multiple R-squared:  0.7593,    Adjusted R-squared:  0.5647
F-statistic: 3.903 on 274 and 339 DF,  p-value: < 0.00000000000000022
```

بعد از fit کردن مدل میتوان با دستور plot چند نمودار برای بررسی عملکرد مدل رسم کرد که این نمودار ها را برای تمام مدل ها دیگر نیز رسم میکینم.

یک بار مختصرا هر کدام را توضیح میدهیم.

نمودار اول نمودار خطای پیشبینی بر اساس مقدار پیش بینی شده است ، هرچقدر نقاط به خط افقی نزدیک تر باشند یعنی مدل ما خطای کمتری دارد و خط قرمز وسط صفحه نیزنشان میدهد که میانگین خطا در قیمت های مختلف چقدر است که بهترین حالت آن درشرایطی است که این خط کاملا صاف باشد. اگر این خط صاف نباشد به این معنی است که شرط linearity در مدل رعایت نشده است و باید تبدیل هایی در متغیر های پیشگو یا برآمد به وجود آید تا مشکل حل شود و همچنین داده های پرت را نیز به ما نشان میدهد. بهترین حالت زمانی است که تراکم داده ها در طول محور x ثابت باشد.

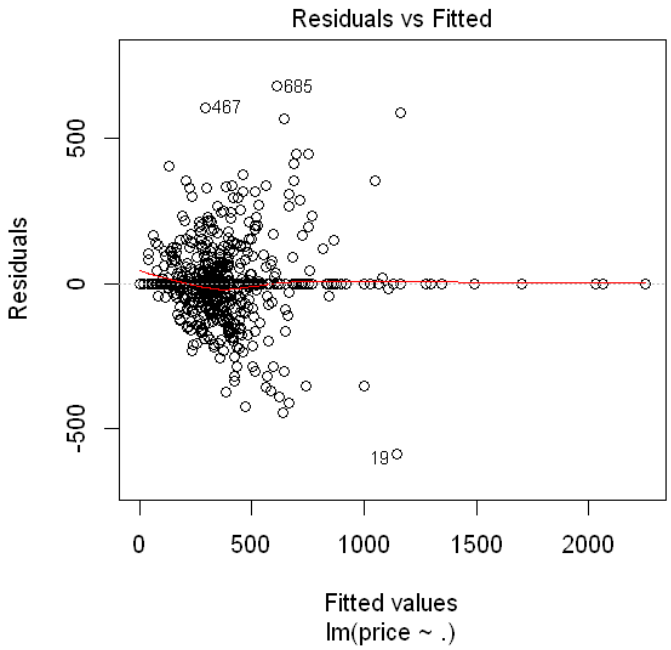

نمودار دوم بررسی میکند که آیا خطا ها از توضیع نرمال پیروی میکنند یا خیر که بهترین حالت این است که تمام نقاط روی خط قرار بگیرند.

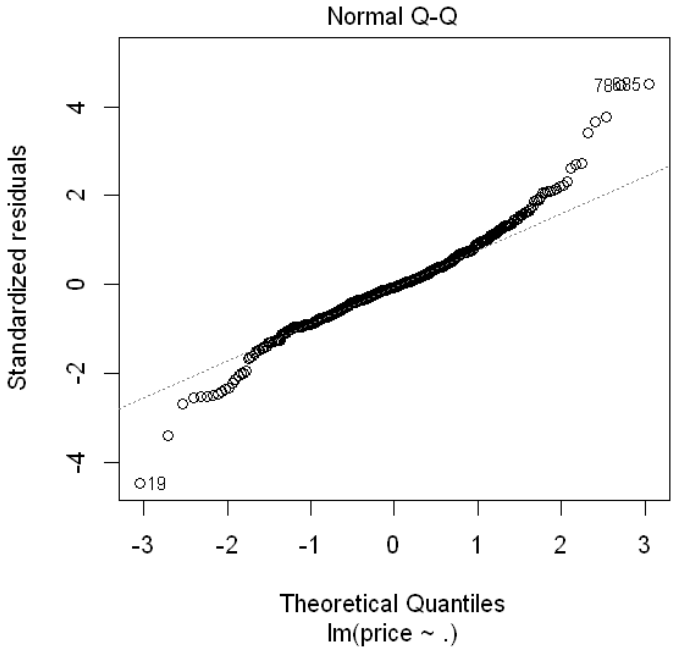

نمودار سوم واریانس خطا را بررسی میکند که در آن بهترین حالت این است که خط قرمز کاملا افقی باشد و توضیع داده ها دور خط قرمز در تمام x ها به یک شکل باشد.

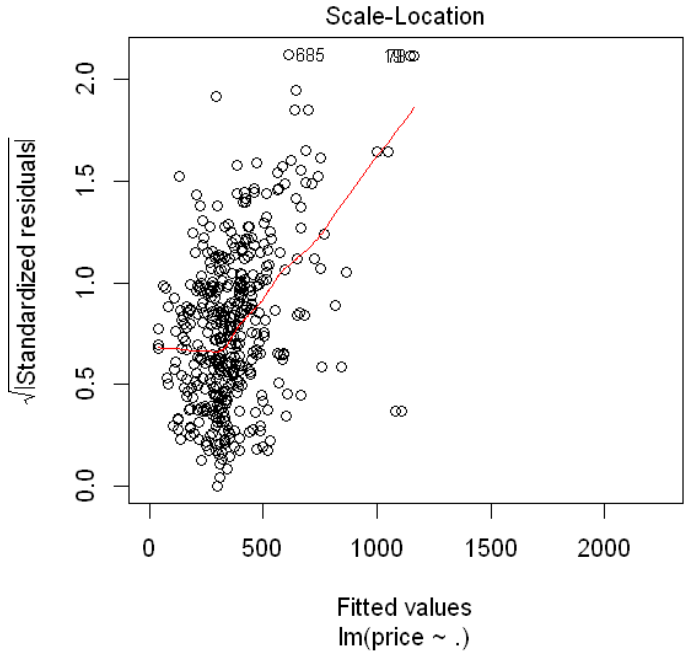

نمودار چهارم نیز خطای استاندارد شده نقاط را بر اساس قدرت آن ها در جابجایی خط رگرسیون نمایش میدهد که از این طریق میتوان داده های پرت را نیز بر اساس معیار فاصله کوک مشخص کرد که حذف آن ها باعث عملکرد بهتر مدل روی بقیه داده ها میشود. اما ما در این جا قصد حذف داده ها را نداریم.

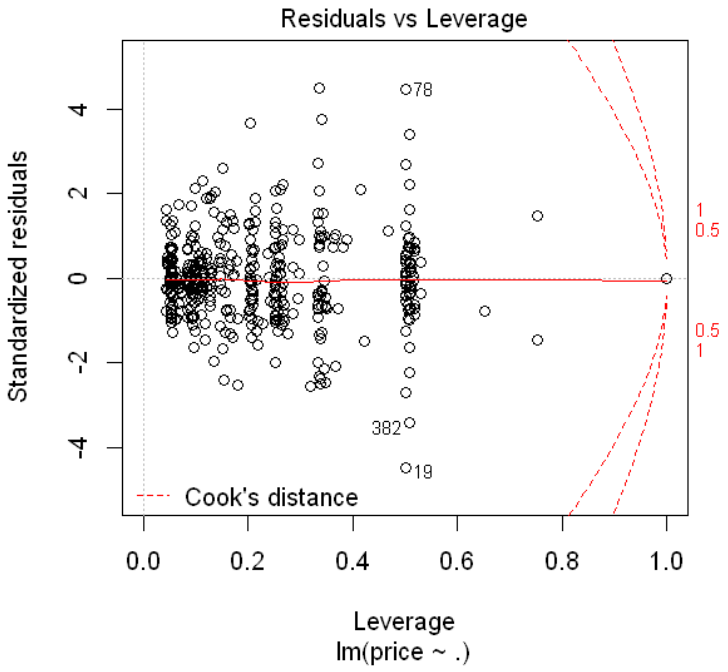

دقت و توضیع خطا ها روی داده های آموزشی و اعتبارسنجی به شکل زیر است.

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.00000000000004703078	137.406	85.20685	-2683.718	2700.118	0.4397862

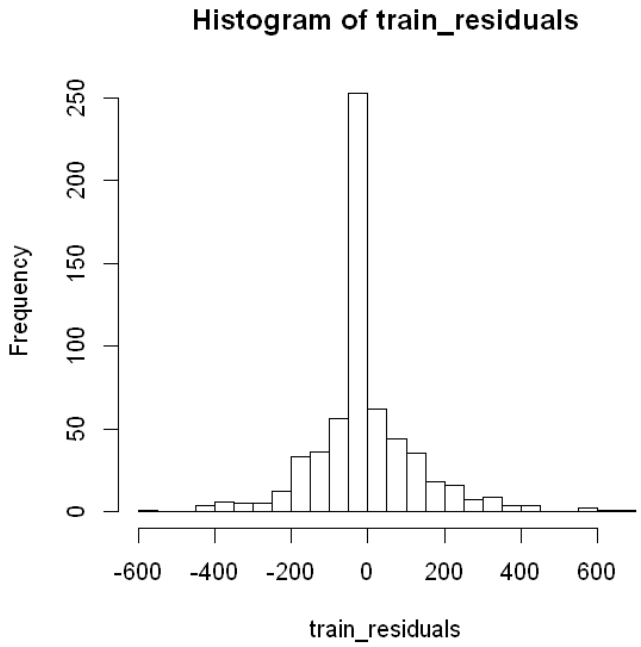

	ME	RMSE	MAE	MPE	MAPE
Test set	71.29738	353.6341	225.9979	-9446.7	9494.791

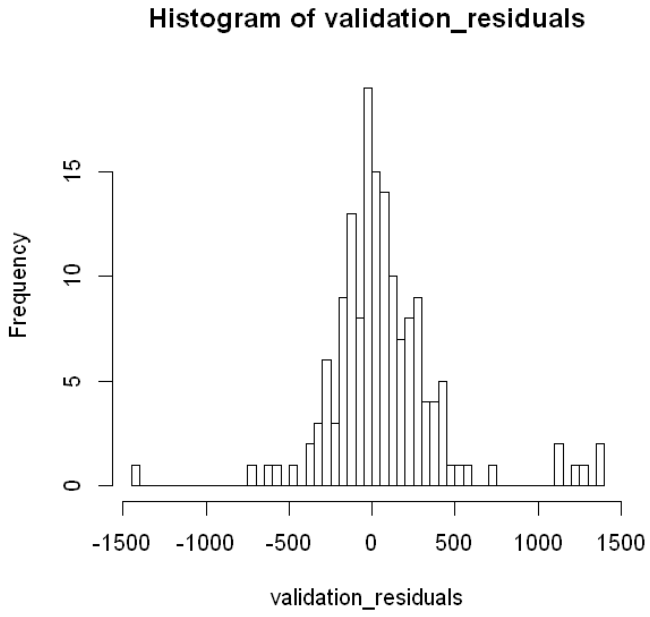

۱،۲ رگرسیون قدم به قدم پیشرو

ابتدا یک فرمول از تمامی متغیر هایی که میتواند وارد مدل شود میسازیم و این فرمول را به عنوان scope به تابع step میدهیم و از یک مدل که تنها یک intercept دارد شروع میکنیم و مدل را گسترش میدهیم.

```
formula.all.variables = formula(lm(price~.,train))
```

```
forward.reg = step(lm(price ~ 1 ,data = train),direction='forward',scope=formula.all.variables)
```

```
Residual standard error: 163.9 on 508 degrees of freedom
Multiple R-squared:  0.7166,    Adjusted R-squared:  0.658
F-statistic: 12.23 on 105 and 508 DF,  p-value: < 0.00000000000000022
```

اطلاعات کامل تر از مدل درون کد موجود است.

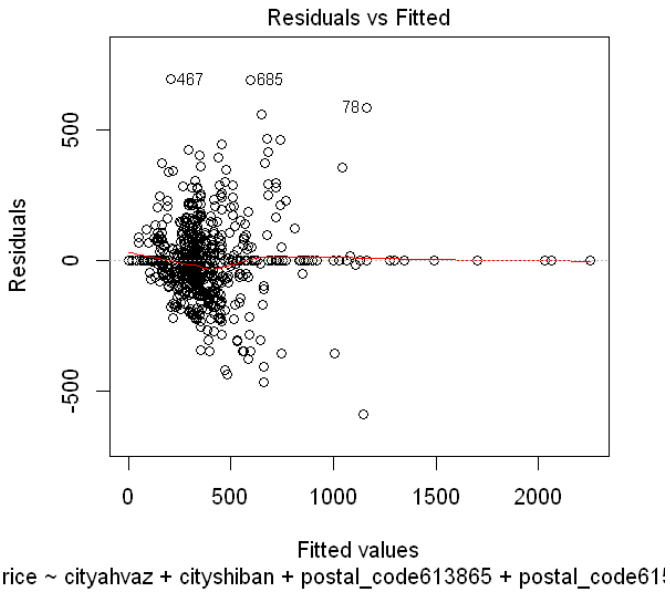

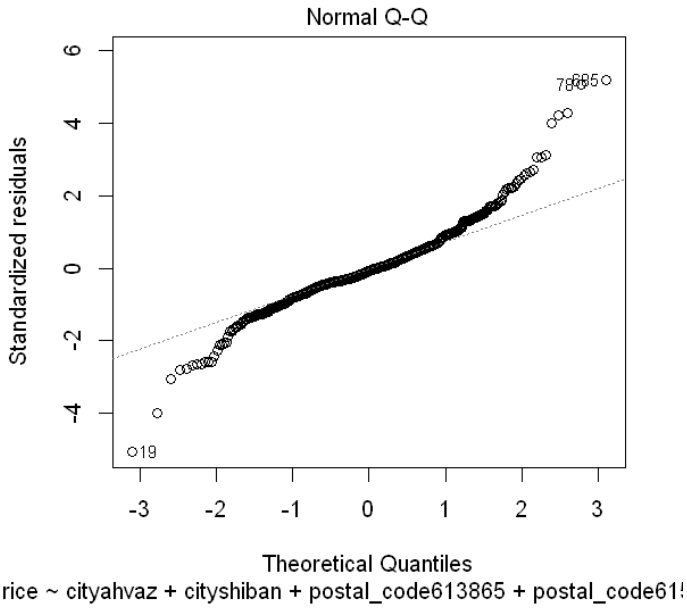

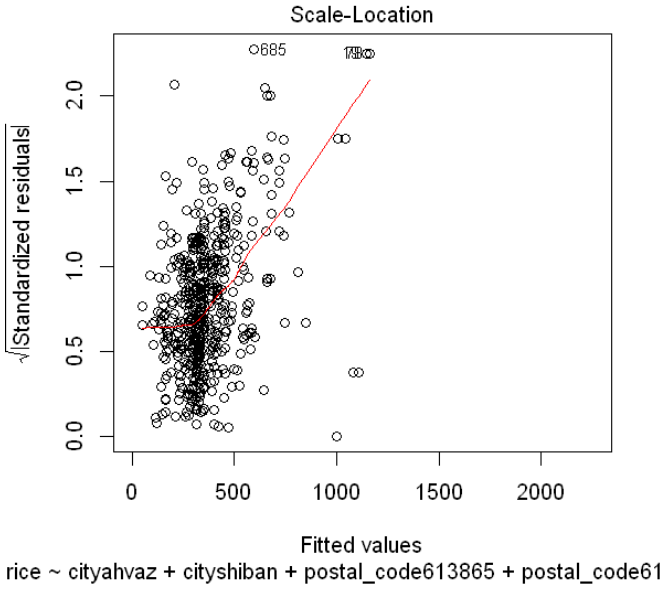

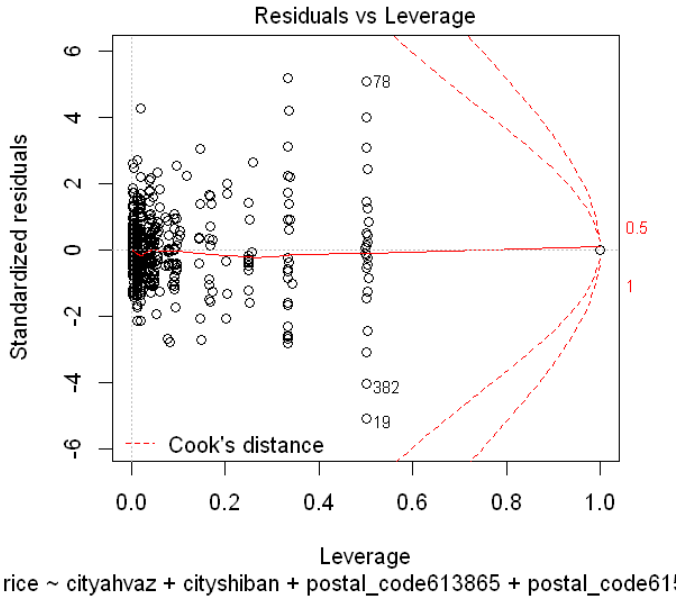

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.00000000000002153634	149.0952	102.6793	-2555.901	2575.02	0.5299685

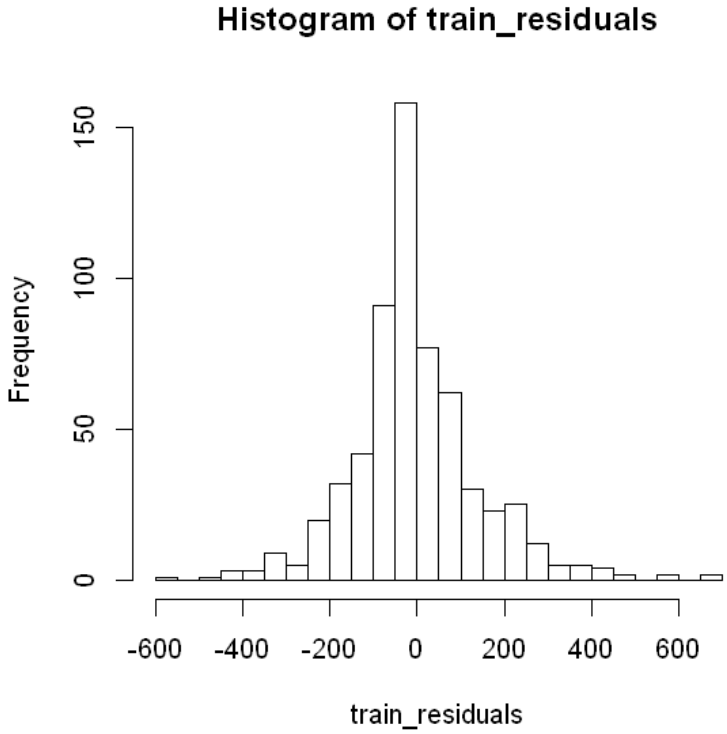

	ME	RMSE	MAE	MPE	MAPE
Test set	63.64744	296.6739	189.6729	-10821.63	10856.77

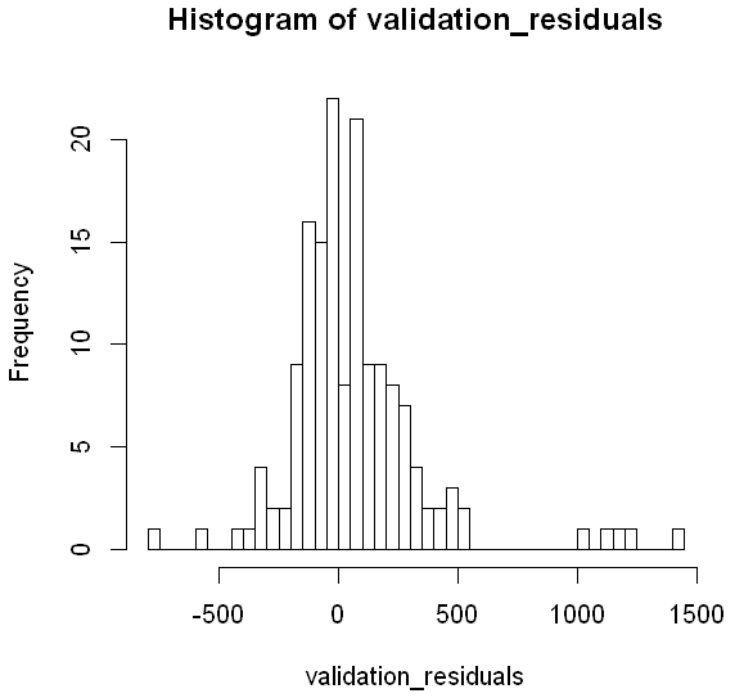

۱،۳ رگرسیون قدم به قدم پسرو

ابتدا یک مدل با استفاده از تمام پیشگو ها میسازیم و سپس در هر مرحله یکی از پیشگو های اضافی را حذف میکنیم.

```
backward.reg = step(lm(price ~ . ,data = train),direction='backward')
```

```
Residual standard error: 165.1 on 505 degrees of freedom
Multiple R-squared:  0.714,     Adjusted R-squared:  0.6528
F-statistic: 11.67 on 108 and 505 DF,  p-value: < 0.00000000000000022
```

اطلاعات کامل تر از مدل درون کد موجود است.

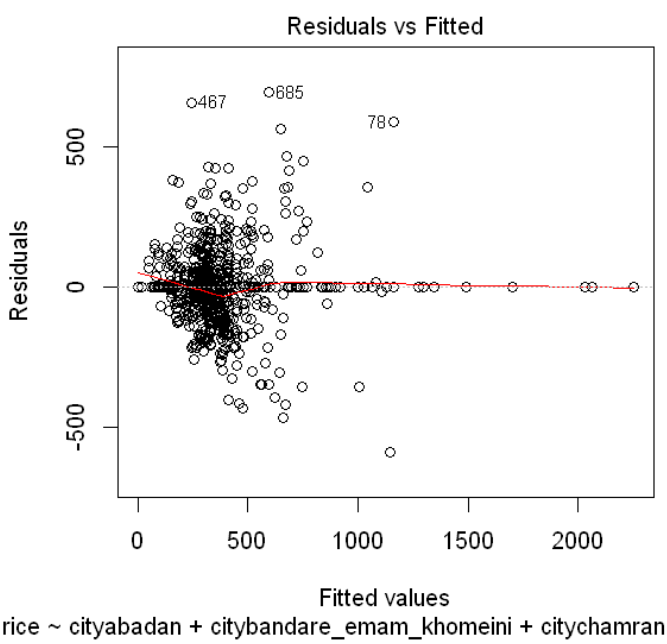

rice ~ cityabadan + citybandare_emam_khomeini + citychamran + cit

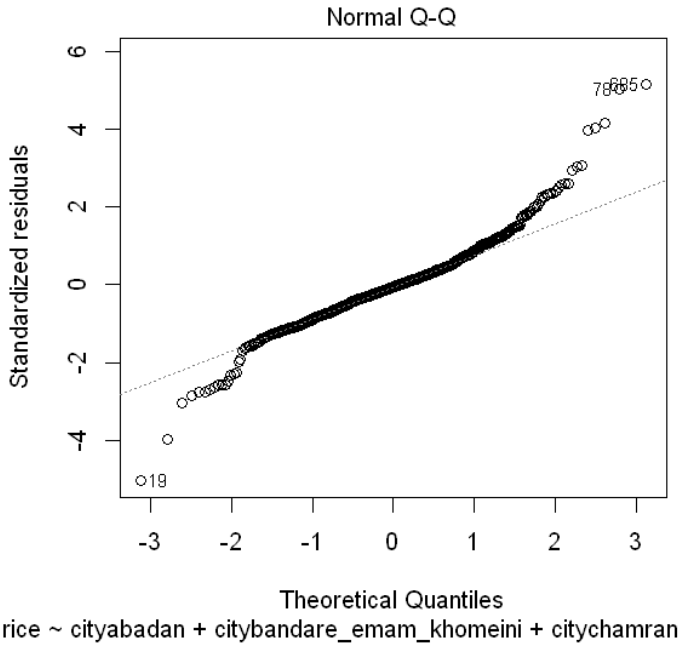

rice ~ cityabadan + citybandare_emam_khomeini + citychamran + cit

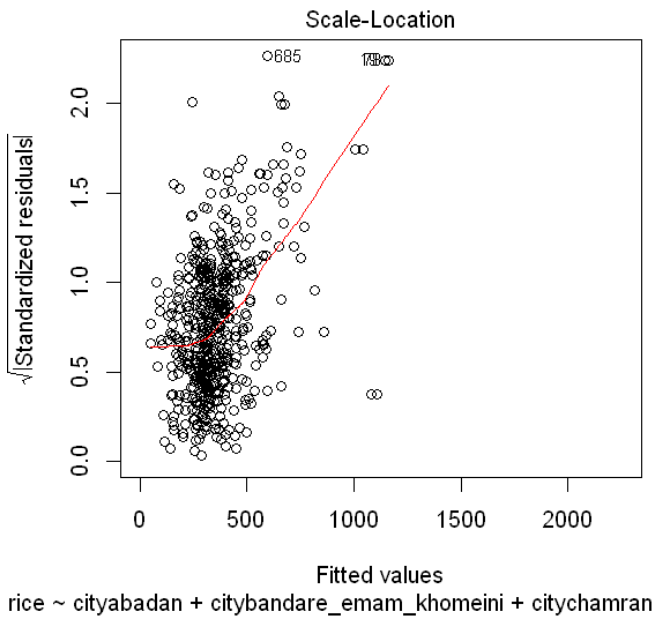

rice ~ cityabadan + citybandare_emam_khomeini + citychamran + cit

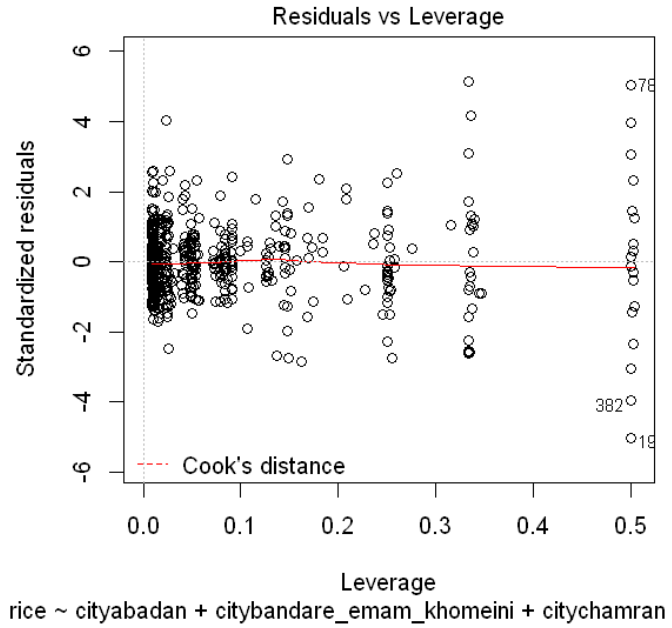

rice ~ cityabadan + citybandare_emam_khomeini + citychamran + cit

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.000000000000003610937	149.7751	104.3567	-2993.646	3013.738	0.5386261

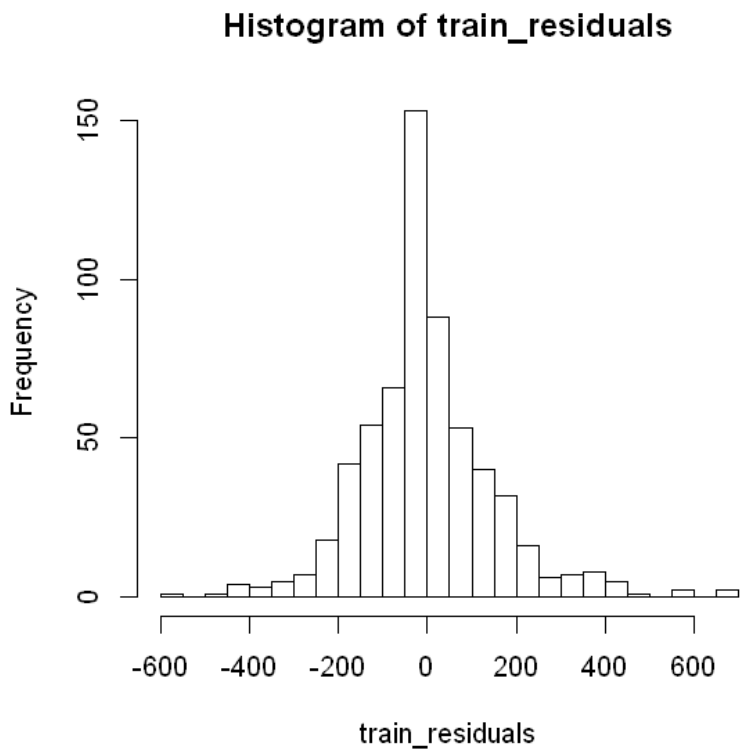

	ME	RMSE	MAE	MPE	MAPE
Test set	59.59292	336.5469	210.0531	-11009.88	11050.56

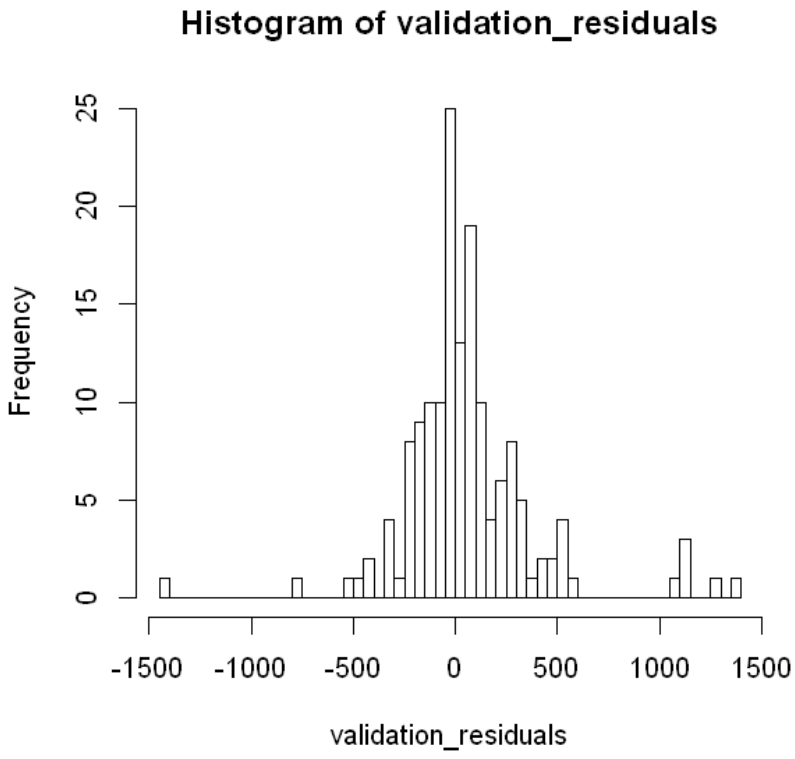

۱،٤ رگرسیون قدم به قدم دوسویه

رگرسیون قدم به قدم مانند رگرسیون پسرو میباشد و از یک مدل با تمام متغیر ها شروع میشود با این تفاوت که در هر مرحله پس از حذف کردن یکی از متغیر ها بررسی میکند که آیا اضافه کردن یکی دیگر از متغیر ها میتواند AIC را پایین بیاورد یا خیر اگر چنین متغیری پیدا کرد آن را به مدل اضافه میکند.

```
stepwise.reg = step(lm(price ~ . ,data = train),direction='both')
```

```
Residual standard error: 163.6 on 500 degrees of freedom
Multiple R-squared:  0.7221,    Adjusted R-squared:  0.6593
F-statistic:  11.5 on 113 and 500 DF,  p-value: < 0.00000000000000022
```

طلاعات کامل تر از مدل درون کد موجود است.

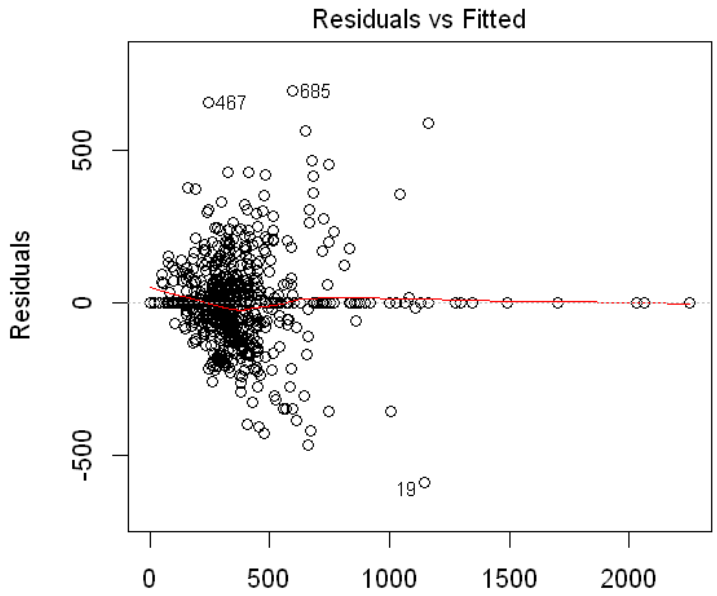

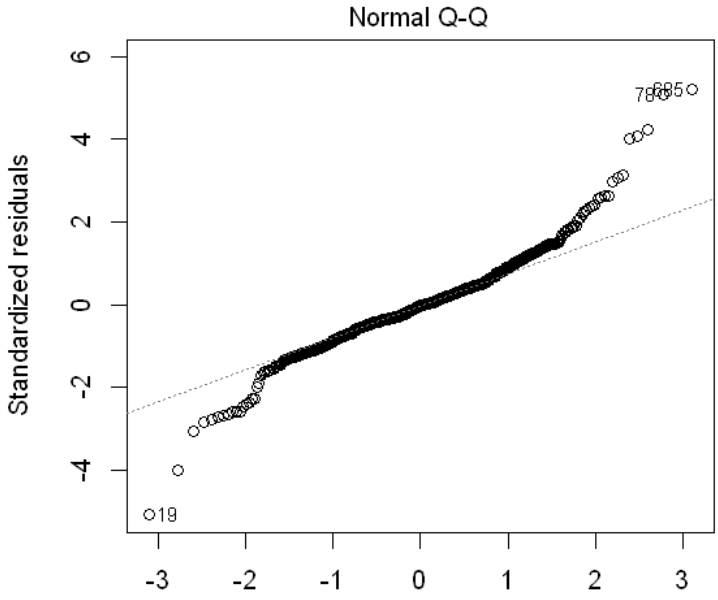

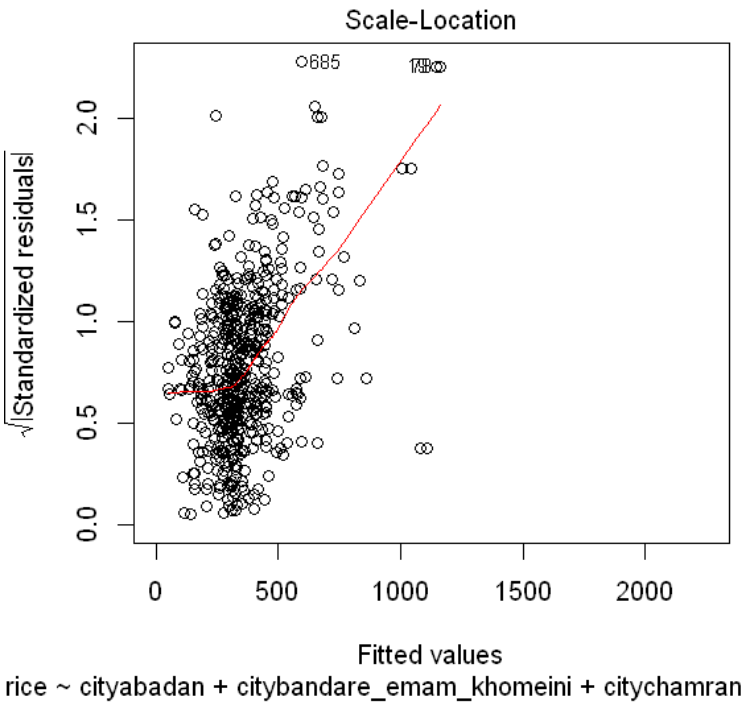

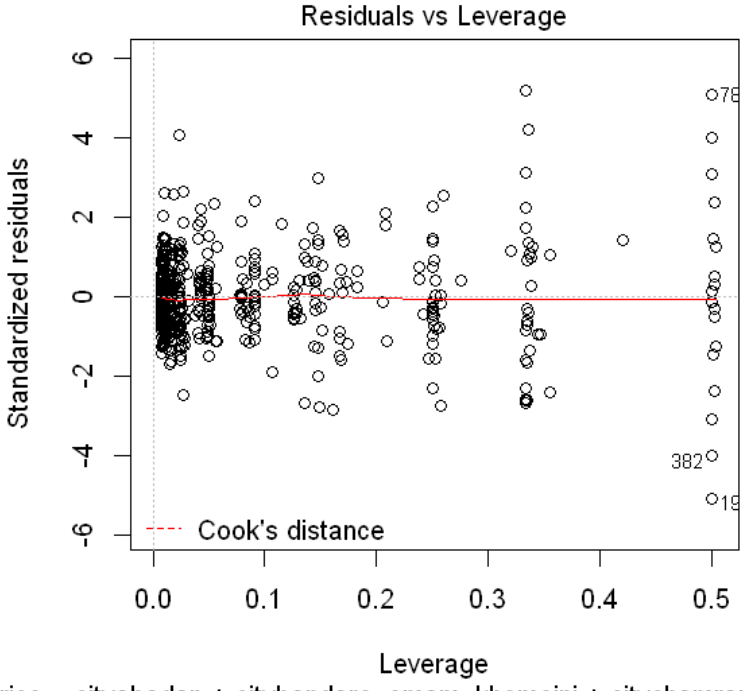

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.00000000000000429018	147.634	102.7167	-2993.936	3013.852	0.5301617

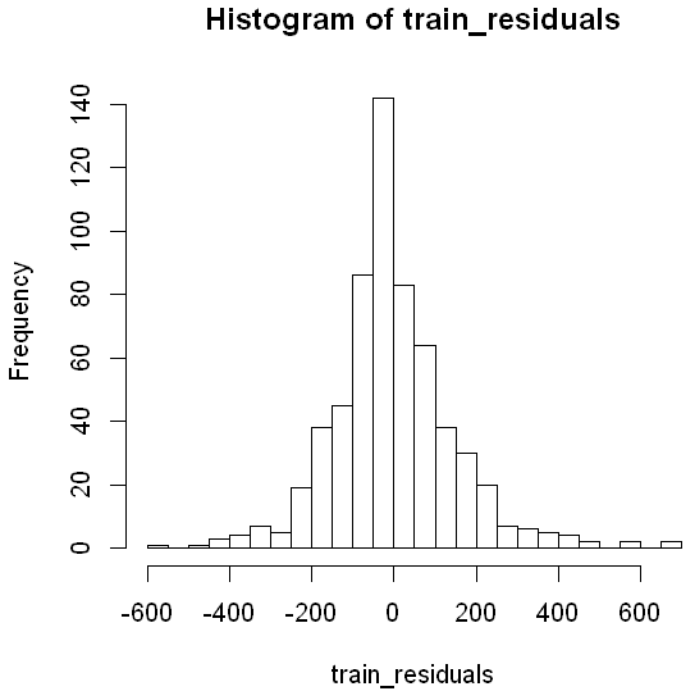

	ME	RMSE	MAE	MPE	MAPE
Test set	66.7623	336.73	209.9644	-10761.34	10803.69

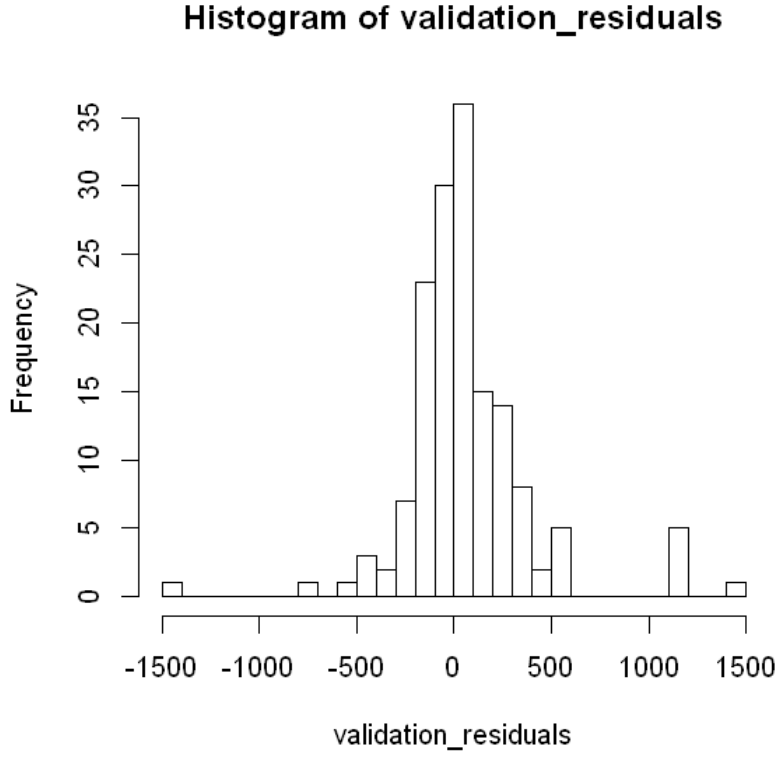

۱،۵ رگرسیون فرسا

این مدل با بررسی کردن تمام ترکیب های مختلف از متغیر های پیشگو و ببرسی عملکرد آن ها بهترین مدل را به شما معرفی میکند.

مزیت این مدل این است که قطعا بهترین مدل را پیدا میکند اما ضعف این مدل این است که زمانی که نیاز است تا این مدل پیدا شود رابطه نمایی با تعداد متغیر ها دارد و برای مثال در این داده ها که تعداد متغیر های پیشگو ۳۲۶ میباشد مدل باید $۲^{۳۲۶}$ رگرسیون عادی را امتحان کند و نتایج را با یکدیگر مقایسه کند.

سعی کردم این مدل را اجرا کنم اما بعد از ۱۸ ساعت مدل موفق به حل این مسئله نشد به همین دلیل فعالیت آن را قطع کردم.

```
exhaustive.reg = regsubsets(price ~ . ,data = train, nbest=1, nvmax = dim(train)[2], method = 'exhaustive',really.big=T)
```

بررسی :

	آموزشی (Train)				
	MAPE	MPE	MAE	RMSE	ME
با تمام متغیر ها	2700.11	-2683.71	85.2	137.4	0
قدم به قدم پیشرو	2572.02	-2555.9	102.67	149.09	0
قدم به قدم پسرو	3013.73	-2993.64	104.35	149.77	0
قدم به قدم دوسویه	3013.85	-2993.93	102.71	147.63	0
فرسا	0	0	0	0	0

آزمایشی (Test)				
MAPE	MPE	MAE	RMSE	ME
9494.79	-9446.7	225.99	353.63	71.29
10856.77	-10821.6	189.67	296.67	63.64
11050.56	-11009.9	210.05	336.54	59.59
10803.69	-10761.3	209.96	336.73	66.76
0	0	0	0	0

بهترین مدل رگرسیون ما مدل رگرسیون قدم به قدم پیشرو بود که توانست Radjusted را نیز به ۰.۶۸ برساند و همچنین خطای MAE و RMSE این مدل روی داده های دیده نشده نسبت به بقیه مدل ها کمتر بود.

۲. K-نزدیک ترین همسایه

در این بخش علاوه بر تمام پیش پردازش هایی که در مدل رگرسیون انجام دادیم لازم است تا داده ها را نرمال نیز بکنیم، زیرا در مدل knn ما با استفاده از پیدا کردن نزدیک ترین همسایه ها به نقطه مورد نظرمان که قصد پیشگویی برای آن را داریم و میانگین گیری از مقادیر متغیر برآمد آن ها پیشگویی را انجام میدهیم و محاسبه این فاصله از فاصله اقلیدسی بین نقاط استفاده میکنیم که فرمول آن به شکل زیر است.

$$d(\mathbf{p},\mathbf{q}) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \cdots + (p_i - q_i)^2 + \cdots + (p_n - q_n)^2}.$$

که در این جا اعداد ۱ تا n مشخص کننده ویژگی های مختلف نقاط p و q هستند.

در این جا برای این اگر یکی از متغیر ها شامل اعداد بزرگتری نسبت به دیگر متغیر ها باشد ، در محاسبه فاصله بین این نقاط تاثیر سایر متغیر ها بسیار کم میشود و عملا متغیری که فاصله بین نقاط را مشخص میکند متغیری است که شامل اعداد بزرگتری میباشد و فاصله این دو نقطه در بقیه متغیر ها در برابر این متغیر قابل چشم پوشی است و این امر باعث میشود که این مدل عملکرد ضعیفی داشته باشد به همین دلیل برای از بین بردن تاثیر مقیاس متغیر های مختلف در این فرمول از نرمال کردن استفاده میکنیم که باعث میشود دامنه تغییر تمام متغیر ها به بازه [0,1] محدود شود.

برای این کار از تابع زیر استفاده میکنیم.

```
normalize <- function(x){
                return ((x-min(x))/(max(x)-(min(x))))
            }
```

و این تابع را روی تمام متغیر ها به جز متغیر برآمد اجرا میکنیم.

و سپس کل داده ها را به دو بخش train و test تقسیم میکنیم.

```
train_index = sample.int(nrow(dummy_khoozestan),0.8*nrow(dummy_khoozestan),replace=F)

X = as.data.frame(lapply(dummy_khoozestan[,-c(17)],normalize))
Y = dummy_khoozestan['price']

x_train = X[train_index,]
y_train = Y[train_index,]
train = cbind(x_train,y_train)

x_test = X[-train_index,]
y_test = Y[-train_index,]
test = cbind(x_test,y_test)
```

در این جا برای برای انتخاب بهترین مدل و همچنین بررسی درست عملکرد مدل قصد داریم که مدل را به روش cross validation روی داده train آموزش دهیم و از روی آن بهترین مقدار k را انتخاب کنیم و سپس عملکرد آن را روی داده test که تا به حال ندیده است بررسی کنیم.

برای این کار ابتدا تابع رو به رو را تعریف میکنیم که وظیفه آن تولید times بار نمونه تصادفی از آرایه y است به طوری که در هر نمونه فقط p*(length(y)) عضو دارد و p عددی بین ۰ و ۱ است.

```
createRandomDataPartition <- function(y, times, p) {
  vec <- 1:length(y)
  n_samples <- round(p * length(y))

  result <- list()
  for(t in 1:times){
    indices <- sample(vec, n_samples, replace = FALSE)
    result[[t]] <- indices
    #names(result)[t] <- paste0("Resample", t)
  }
  names(result) <- prettySeq(result)
  result
}
```

که نمونه عملکرد آن را در اینجا مشاهده میکنید.

۵ نمونه از داده های (1,2,3,4,5,6,7,8,9,10) به طوری که

طول هر نمونه برابر ۱۰ * ۰.۶ = ۶ میباشد.

```
createRandomDataPartition(y=1:10 , time=5 , p=0.6)
```

```
$Resample1
6  9  10  4  3  8

$Resample2
3  9  8  5  1  4

$Resample3
7  8  3  9  5  10

$Resample4
5  10  4  9  8  7

$Resample5
5  8  4  1  2  9
```

قصد داریم عملکرد مدل ما به این شکل باشد که مدل را برای k های مختلف به تعداد نمونه ابتدا روی اندیس هایی که در نمونه وجود دارد آموزش دهیم و سپس از اندیس هایی که در نمونه وجود ندارد برای اعتبار سنجی داده ها استفاده کنیم و در نهایت در هر k شاخص های دقت را با میانگین گیری از شاخص های دقت مربوط به نمونه های آن k مشخص کنیم تا بتوانیم به درستی این k ها را با هم مقایسه کنیم و در نهایت عملکرد بهترین k را روی داده های test بررسی کنیم.

در این جا باید یک trainControl بسازیم که عملکرد یادگیری را مدیریت کند و پارامتر index را برابر با اندیس نمونه های تصادفی از داده های آموزشی در نظر میگیریم و به این ترتیب اندیس هایی که در آن نمونه وجود نداشته باشد به عنوان داده های اعتبارسنجی بررسی میشوند.

```
set.seed(1234)
n_repeats <- 20
train_fraction <- 0.8

parts <- createRandomDataPartition(1:nrow(train), times = n_repeats, p = train_fraction)

ctrl <- trainControl(method = "repeatedcv",  ## The method doesn't matter
                     index= parts,
                     savePredictions = TRUE
                     )
```

سپس فرایند یادگیری را به وسیله تابع train از کتابخانه caret به این صورت انجام میدهیم.

```
m1 <- train(y_train ~. ,
            tuneGrid = expand.grid(k=1:30),
            data = train,
            metric = 'MAE',
            method = 'knn',
            trControl = ctrl)
```

همان طور که مشاهده میکنید در این جا به جای استفاده از ۶۱۴ نمونه موجود در train تنها از ۴۹۱ عدد از این نمونه ها به صورت ۱۰-fold استفاده شده است و شاخص های دقتی که در صفحه بعد مشاهده میکنید میانگین بین این ۱۰ نمونه به ازای k های مختلف میباشند.

```
k-Nearest Neighbors

614 samples
326 predictors

No pre-processing
Resampling: Cross-Validated (10 fold, repeated 1 times)
Summary of sample sizes: 491, 491, 491, 491, 491, 491, ...
Resampling results across tuning parameters:
```

و چون در این جا معیار ما برای انتخاب بهترین k کم کردن MAE بود

k=6 انتخاب شده است که همان طور که میبینید کمترین RMSE

را نیز دارد و Rsquared آن نیز بعد از k=3 ، بالاترین مقدار است و

در کل k=6 عدد خوبی برای این مدل و این داده ها میباشد.

در این جا میتوانید نمودار مقدار MAE بر حسب k را نیز مشاهده کنید.

k	RMSE	Rsquared	MAE
1	295.9929	0.1371818	185.2124
2	264.8218	0.1703314	174.5649
3	249.6771	0.2182988	165.7721
4	249.4402	0.2115939	165.4578
5	246.9486	0.2100887	163.8605
6	245.3673	0.2166829	163.3118
7	246.0461	0.2079222	163.9413
8	246.7112	0.2002395	164.6784
9	247.0609	0.1976539	165.8000
10	247.8849	0.1907857	167.0615
11	249.0790	0.1828342	167.8993
12	249.4082	0.1805639	168.6234
13	250.0844	0.1768484	169.8711
14	250.0874	0.1788288	170.4537
15	249.9776	0.1782771	170.6001
16	251.6690	0.1685201	171.7831
17	251.2107	0.1692580	171.8539
18	251.8960	0.1663435	172.4794
19	251.6729	0.1642199	172.5186
20	251.9242	0.1586018	172.6902
21	252.0149	0.1585415	172.3350
22	251.8685	0.1590744	172.0873
23	252.1537	0.1607392	172.5145
24	252.3013	0.1601493	172.7714
25	252.5642	0.1586088	173.1863
26	252.8201	0.1569045	173.5999
27	253.3949	0.1531235	174.0665
28	253.4523	0.1524731	173.9409
29	253.8992	0.1493840	174.3817
30	253.9711	0.1498748	174.5646

MAE was used to select the optimal model using the smallest value.
The final value used for the model was k = 6.

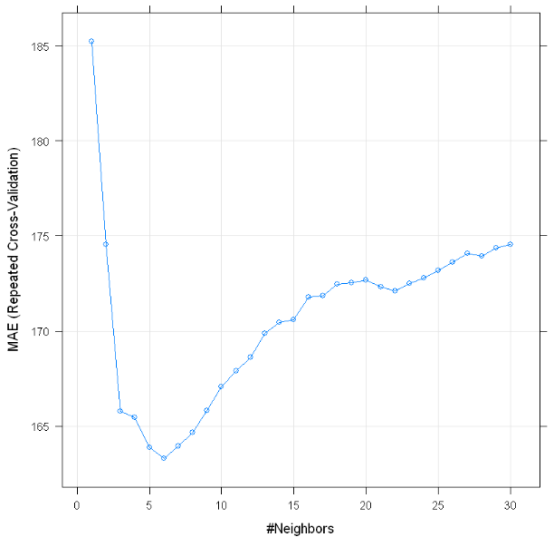

حال زمان بررسی عملکرد مدل روی داده جدید است که مدل تا به این جا ندیده است.

برای این کار از داده test استفاده میکنیم و عملکرد آن به شکل زیر است.

```
accuracy(predict(m1,x_test),y_test)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	5.843856	277.2868	182.0896	-2107.498	2131.766

برای بهتر کردن این مدل میتوان به جای استفاده از میانگین ساده از میانگین وزن دار استفاده کرد و تاثیر فاصله نقاط را نیز در پیشبینی در نظر گرفت.

موفق به پیدا کردن پکیجی که در R این کار را به خوبی انجام داده باشد نشدم (چند مورد وجود داشت که نتوانستم نتیجه مطلوب بگیرم)

به همین دلیل خودم سعی کردم پیاده سازی آن را انجام دهم اما

این پیاده سازی نیز برای بعضی از نقاط مقدار بینهایت را پیشبینی

میکرد که نتوانستم متوجه شوم چه تغییری برای حل این مشکل

باید روی این تابع اعمال کنم.

```
weighted_average.knn <- function(x_train,x_test,y_train,k){

        df = FNN::knnx.index(data = x_train , query=x_test , k=k)
        values = data.frame(1:nrow(x_test))
        for(var in 1:k)
         {
          values = cbind(values,y_train[df[,var]])
         }
        values = values[-c(1)]
        dist = FNN::knnx.dist(data = x_train , query=x_test , k=k)
        weights = 1/dist
        print(as.data.frame(rowSums(weights)))
        return (rowSums(values * weights)) / as.data.frame(rowSums(weights))

        }
```

۳. درخت های پیشگو

تمام پیش پردازش ها دقیقا مانند رگرسیون میباشند.

برای ساخت درخت از تابع rpart استفاده میکنیم و چون قصد پیشبینی برای این داده ها را داریم و نه رده بندی به جای اینکه پارامتر method آن را برابر با class قرار دهیم آن را برابر با anova قرار میدهیم.

۳،۱ درخت پیشگو بدون تنظیم کردن پارامتر ها

در مرحله اول یک مدل از درخت را بدون تنظیم کردن هیچکدام از پارامتر ها آموزش میدهیم و عملکرد آن را بررسی میکنیم.

```
reg.tree = rpart(formula = y_train~. , data = train, method = "anova")
```

درختی که در نتیجه این دستور به وجود می آید و قوانین آن را در زیر مشاهده میکنید

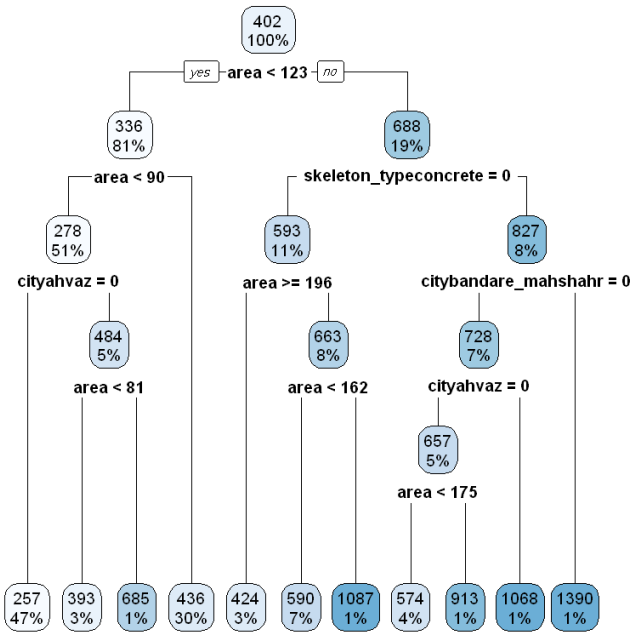

y_train																				cover
257	when	area	<	90									&	cityahvaz	is	0				47%
393	when	area	<	81									&	cityahvaz	is	1				3%
424	when	area	>=			196	&	skeleton_typeconcrete	is	0										3%
436	when	area	is	90	to	123														30%
574	when	area	is	123	to	175	&	skeleton_typeconcrete	is	1	&	cityahvaz	is	0	&	citybandare_mahshahr	is	0		4%
590	when	area	is	123	to	162	&	skeleton_typeconcrete	is	0										7%
685	when	area	is	81	to	90							&	cityahvaz	is	1				1%
913	when	area	>=			175	&	skeleton_typeconcrete	is	1	&	cityahvaz	is	0	&	citybandare_mahshahr	is	0		1%
1068	when	area	>=			123	&	skeleton_typeconcrete	is	1	&	cityahvaz	is	1	&	citybandare_mahshahr	is	0		1%
1087	when	area	is	162	to	196	&	skeleton_typeconcrete	is	0										1%
1390	when	area	>=			123	&	skeleton_typeconcrete	is	1					&	citybandare_mahshahr	is	1		1%

دقت مدل روی داده های آموزشی و آزمایشی نیز به شکل زیر میباشد.

```
accuracy(predict(reg.tree,x_train),y_train)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	-0.00000000000004001206	196.6246	133.6232	-5960.619	5981.634

```
accuracy(predict(reg.tree,x_test),y_test)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	45.25621	257.2425	159.983	-1699.248	1729.426

برای بهبود عملکرد این مدل ابتدا قصد داریم یک درخت با بیش ترین شاخه ممکن را بسازیم و سپس با هرس کردن این درخت generalization را در آن بالا ببریم تا روی داده های جدید هم عملکرد خوبی داشته باشد.

۳,۲ عمیق ترین درخت پیشگو

برای ساخت این درخت تابع rpart را با cp برابر با ۰ اجرا میکنیم که باعث میشود درخت برای اضافه کردن شاخه جدید جریمه نشود و این کار باعث میشود که عمیق ترین درخت ممکن ساخته شود.

```
deep.reg.tree = rpart(formula = y_train~. , data = train, method = "anova", cp=0)
```

درخت خروجی به شکل زیر است.

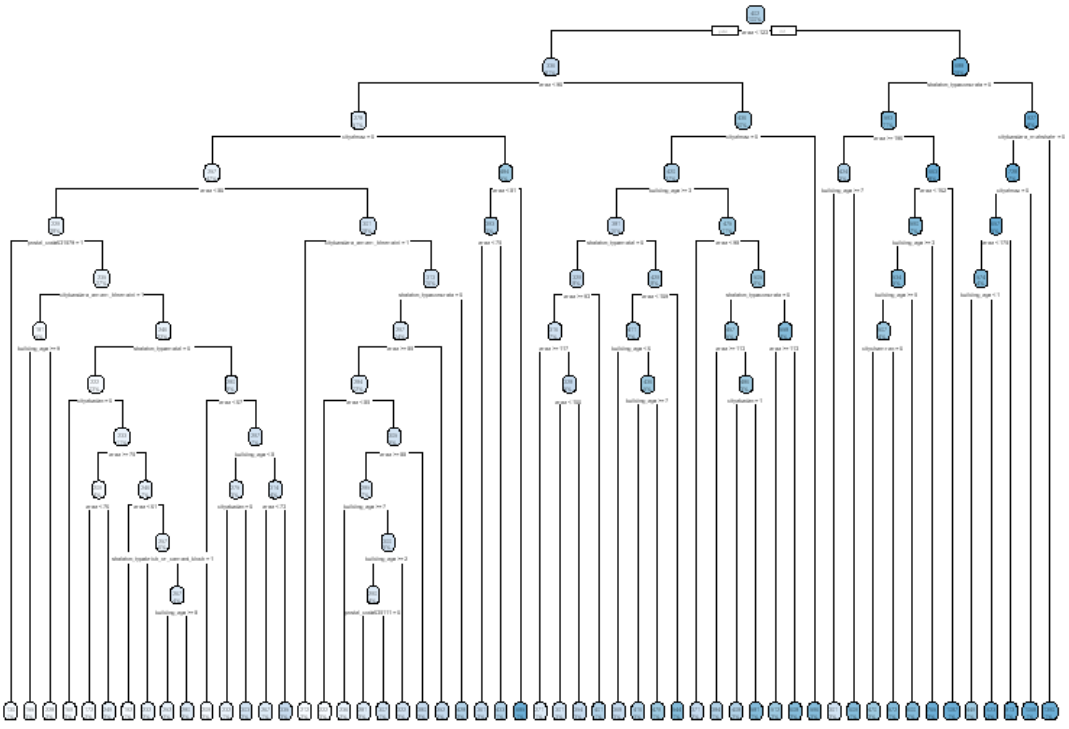

همان طور که مشاهده میکنید این درخت قواعد تصمیم بسیار زیادی دارد که باعث میشود بیش از حد روی داده آموزشی fit شود و از generalization کافی برای داشتن عملکرد خوب روی داده آزمایشی برخوردار نباشد.

```
accuracy(predict(deep.reg.tree,x_train),y_train)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	-0.00000000000002256642	176.3462	113.7177	-4872.698	4891.876

```
accuracy(predict(deep.reg.tree,x_test),y_test)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	42.81508	259.4333	151.7825	-1755.838	1785.949

حالا برای بالا بردن generalization و بیشتر کردن خطا روی داده های آموزشی میخواهیم درخت را هرس کنیم و برخی از این شاخه های اضافی را حف کنیم. برای این کار به جدول cp های مختلف موجود برای این درخت مراجعه میکنیم که برخی از مقادیر آن را در زیر مشاهده میکنید.

در این جا یکبار مقدار cp را انتخاب میکنیم که کمترین Xerror را داشته باشد که در این جا در سطر ۱۴ قرار دارد و از آن جا که خود این مقدار xerror ممکن است دارای خطا باشد که مقدار آن در سطر xstd نوشته شده است دامنه جابجایی xerror را برای این مقدار حساب میکنیم و از آن جا که هدف ما generalization هست میخواهیم تا حد امکان در این جدول به سمت بالا حرکت کنیم و تعداد شاخه های موجود در درخت را کاهش دهیم پس xerror + xstd را محاسبه میکنیم xerror ای را پیدا میکنیم که از این مقدار کمتر باشد و از بقیه xerror های کمتر از این مقدار بزرگتر باشد و cp مربوط به این سطر را به عنوان cp در درخت با بهترین هرس انتخاب میکنیم.

	CP	nsplit	rel error	xerror	xstd
1	0.240793018	0	1.00000	1.00425	0.13557
2	0.059847642	1	0.75921	0.78844	0.11014
3	0.042885368	2	0.69936	0.73839	0.11272
4	0.027998852	4	0.61359	0.75817	0.11512
5	0.023601447	5	0.58559	0.74939	0.11563
6	0.020250407	7	0.53839	0.75634	0.11575
7	0.014443176	8	0.51814	0.76050	0.11585
8	0.010966263	9	0.50369	0.75430	0.11458
9	0.009908470	10	0.49273	0.74085	0.11506
10	0.009469504	11	0.48282	0.73929	0.11506
11	0.008377270	12	0.47335	0.73854	0.10821
12	0.007361642	13	0.46497	0.74018	0.10872
13	0.007339947	14	0.45761	0.73618	0.10872
14	0.005140450	15	0.45027	0.72909	0.10872
15	0.004330327	16	0.44513	0.73782	0.11025
16	0.003150177	17	0.44080	0.73954	0.11029
17	0.003088965	18	0.43765	0.73763	0.10937
18	0.002805694	20	0.43147	0.73763	0.10937
19	0.002200956	21	0.42867	0.73532	0.10907
20	0.002152135	22	0.42646	0.74394	0.11085
21	0.002138819	24	0.42216	0.74735	0.11103
22	0.001631756	27	0.41574	0.74260	0.10713
23	0.001438326	30	0.41084	0.74256	0.10695
24	0.001183281	31	0.40940	0.74725	0.10695
25	0.001140911	32	0.40822	0.74503	0.10691
26	0.001116409	33	0.40708	0.74533	0.10691
27	0.000977614	34	0.40596	0.74958	0.10695
28	0.000964405	35	0.40499	0.74801	0.10696
29	0.000883467	36	0.40402	0.74817	0.10696
30	0.000725336	37	0.40314	0.74653	0.10693
31	0.000650813	38	0.40241	0.74742	0.10695
32	0.000559276	39	0.40176	0.74772	0.10695
33	0.000524747	41	0.40064	0.74608	0.10659
34	0.000510447	42	0.40012	0.74606	0.10659
35	0.000508986	43	0.39961	0.74606	0.10659

۳،۳ عمیق ترین درخت پیشگو (هرس شده با کمترین xerror)

```
pruned.deep.reg.tree = prune(deep.reg.tree,cp=deep.reg.tree$cptable[which.min(deep.reg.tree$cptable[,'xerror']),'CP'])
```

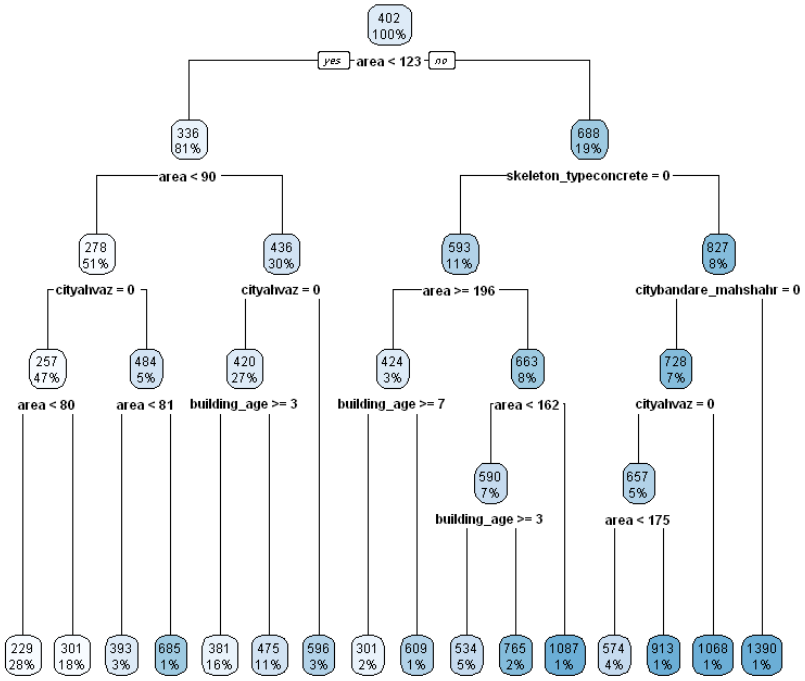

y_train		.1	.2	.3	.4	.5	.6	.7	.8	...	.1	.2	.3	.4	.5	.6	.7	.8	cover
229	when	area	<	80			&	cityahvaz	is	...									28%
301	when	area	is	80	to	90	&	cityahvaz	is	...									18%
301	when	area	>=			196				...	0	&	building_age	>=	7				2%
381	when	area	is	90	to	123	&	cityahvaz	is	...		&	building_age	>=	3				16%
393	when	area	<	81			&	cityahvaz	is	...									3%
475	when	area	is	90	to	123	&	cityahvaz	is	...		&	building_age	<	3				11%
534	when	area	is	123	to	162				...	0	&	building_age	>=	3				5%
574	when	area	is	123	to	175	&	cityahvaz	is	...	1				&	citybandare_mahshahr	is	0	4%
596	when	area	is	90	to	123	&	cityahvaz	is	...									3%
609	when	area	>=			196				...	0	&	building_age	<	7				1%
685	when	area	is	81	to	90	&	cityahvaz	is	...									1%
765	when	area	is	123	to	162				...	0	&	building_age	<	3				2%
913	when	area	>=			175	&	cityahvaz	is	...	1				&	citybandare_mahshahr	is	0	1%
1068	when	area	>=			123	&	cityahvaz	is	...	1				&	citybandare_mahshahr	is	0	1%
1087	when	area	is	162	to	196				...	0								1%
1390	when	area	>=			123				...	1				&	citybandare_mahshahr	is	1	1%

```
accuracy(predict(pruned.deep.reg.tree,x_train),y_train)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	0.000000000000000792294	187.9625	126.7318	-6084.495	6105.274

```
accuracy(predict(pruned.deep.reg.tree,x_test),y_test)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	35.27346	252.3743	153.564	-1519.289	1547.558

۳،٤ عمیق ترین درخت پیشگو (بهترین هرس)

```
best.pruned.deep.reg.tree = prune(deep.reg.tree,cp=0.059847642)
```

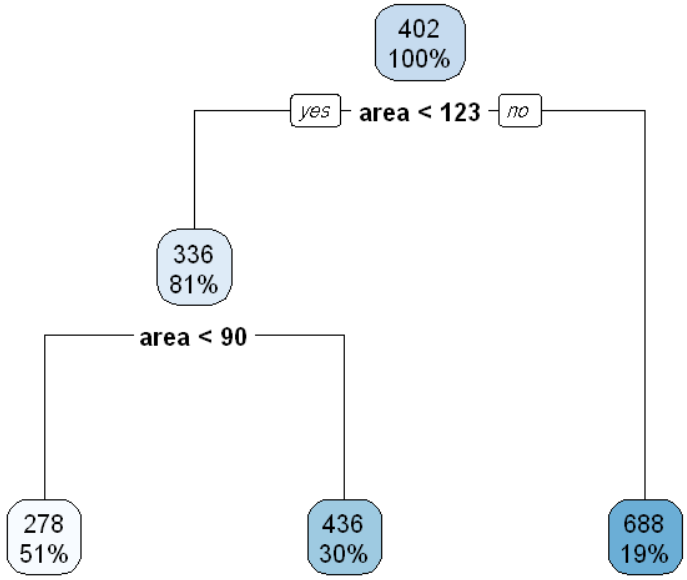

y_train						cover
278	when	area	<	90		51%
436	when	area	is	90	to 123	30%
688	when	area	>=		123	19%

```
accuracy(predict(best.pruned.deep.reg.tree,x_train),y_train)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	-0.000000000000001883166	234.2528	152.3075	-6204.969	6226.402

```
accuracy(predict(best.pruned.deep.reg.tree,x_test),y_test)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	49.27933	270.3546	167.2234	-1842.7	1872.237

همان طور که مشاهده میکنید این کار باعث بالا رفتن خطا روی داده train شد و وابستگی مدل را به داده train کم کرد و generalization مدل را بالا برد.

۳,۵ جنگل تصادفی

در این جا برای ساختن جنگل از ۱۰۰ درخت استفاده میکنیم.

```
random.forest = randomForest(x=x_train, y=y_train, ntree=100, importance=T, nodesize=4)
```

```
accuracy(predict(random.forest,x_train),y_train)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	5.204199	88.16244	55.99443	-2299.6	2308.987

```
accuracy(predict(random.forest,x_test),y_test)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	44.75623	250.0397	148.2198	-1708.236	1735.545

در زیر نیز تاثیر هر یک از متغیر ها را در این جنگل مشاهده میکنید.

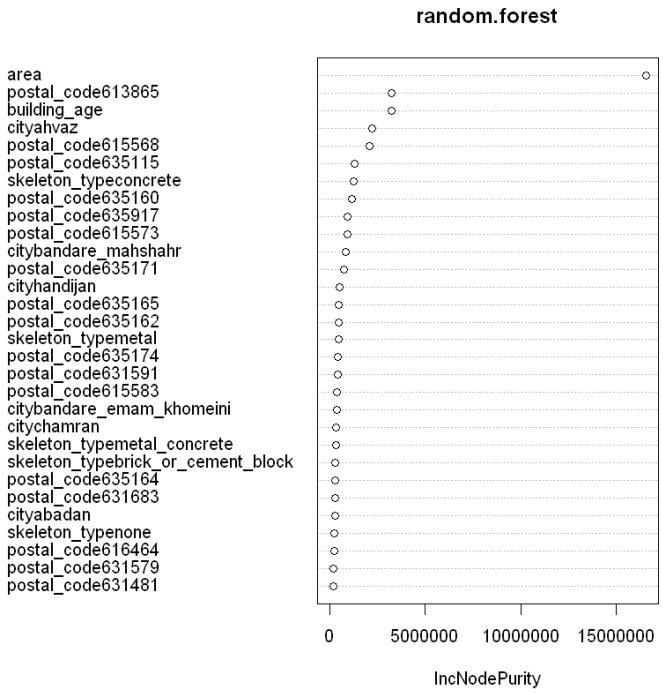

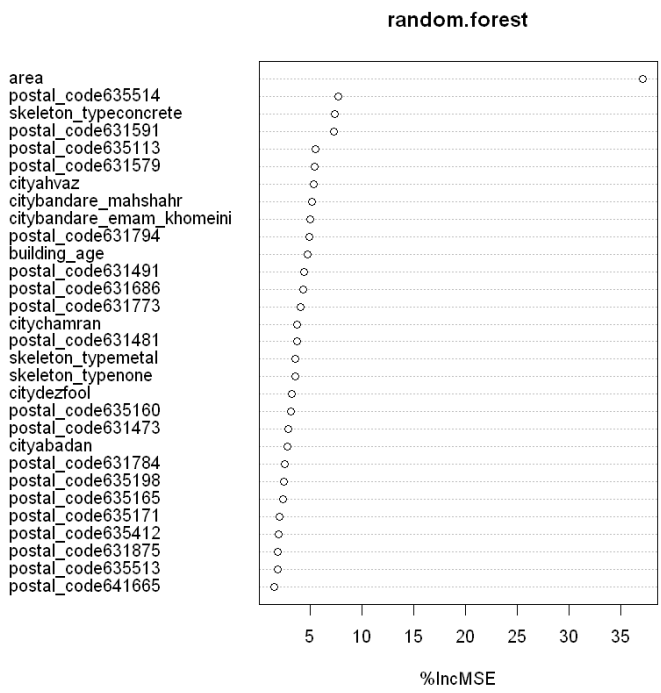

در نمودار صفحه بعد نیز میتوان به شکل دقیق تر تصمیم های این جنگل را بررسی کرد.

randomForest(x=x_train, y=y_train, ntree=100, nodesize=4, importance=T)

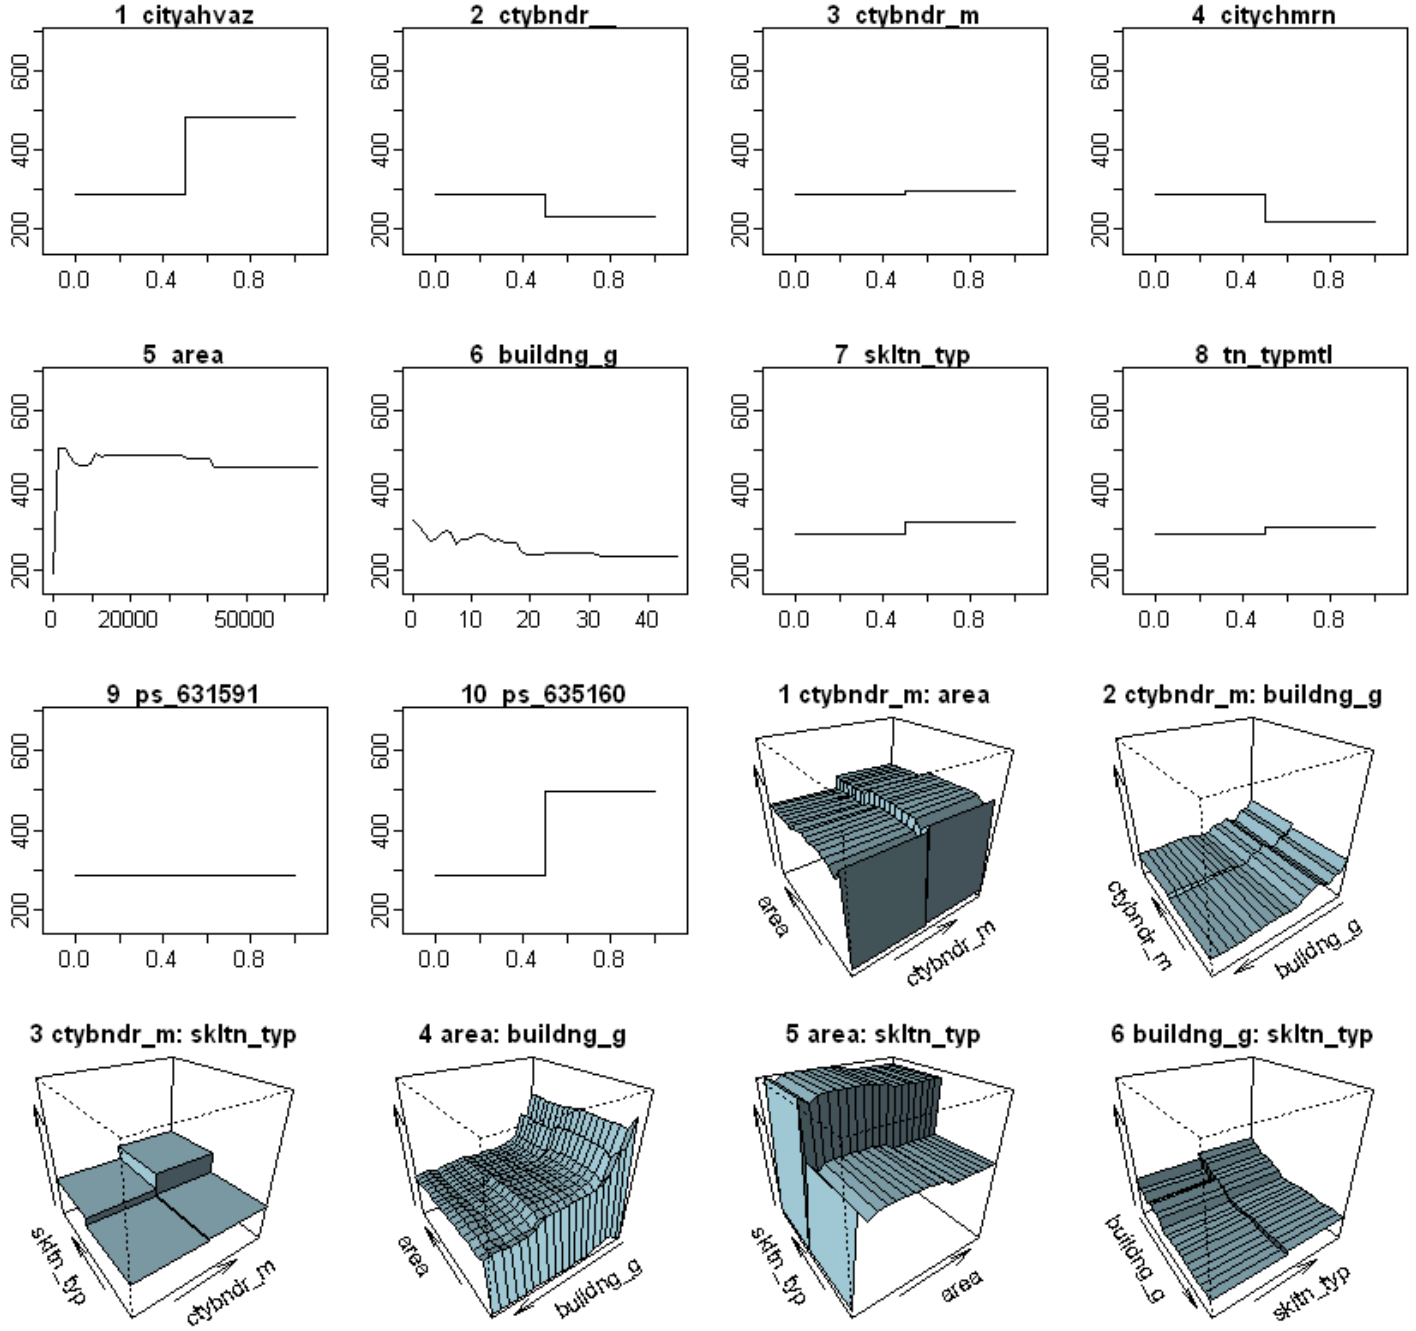

۳,۶ درخت تقویت شده

برای ساخت درخت نقویت شده نیز از کتابخانه gbm و روش ۱۰-fold cross validation روی داده آموزشی استفاده میکنیم و در نهایت عملکرد آن را روی داده آزمایشی بررسی میکنیم.

```
set.seed(101)
boosted.tree = gbm(y_train~. , data=train, cv.folds = 10)
```

در این جا نیز برخی از مهم ترین ویژگی های تاثیر گذار در این مدل و سطح اهمیتشان را مشاهده میکنید.

	var	rel.inf
area	area	72.9519090
cityahvaz	cityahvaz	13.1132179
skeleton_typeconcrete	skeleton_typeconcrete	5.2239214
building_age	building_age	4.2112154
citybandare_mahshahr	citybandare_mahshahr	2.5276543
citychamran	citychamran	1.2785502
cityabadan	cityabadan	0.2850227
citybandare_emam_khomeini	citybandare_emam_khomeini	0.2734410
skeleton_typenone	skeleton_typenone	0.1350681
citybehbahan	citybehbahan	0.0000000

عملکرد آن نیز به شکل زیر میباشد

```
accuracy(predict(boosted.tree,x_train),y_train)
```

```
Using 100 trees...
```

	ME	RMSE	MAE	MPE	MAPE
Test set	2.448334	205.4627	134.6677	-6076.502	6097.818

```
accuracy(predict(boosted.tree,x_test),y_test)
```

```
Using 100 trees...
```

	ME	RMSE	MAE	MPE	MAPE
Test set	39.19129	244.9458	148.4321	-1824.321	1850.706

بررسی :

	آموزشی (Train)				
	ME	RMSE	MAE	MPE	MAPE
درخت بدون تنظیم cp	0	196.62	133.62	-5960.61	5981.63
عمیق ترین درخت	0	176.34	113.71	-4872.69	4891.87
هرس بر اساس xerror	0	187.96	126.73	-6084.49	6105.27
بهترین هرس	0	234.25	152.3	-6204.96	6226.4
جنگل تصادفی	5.2	86.16	55.99	-2299.6	2308.98
درخت تقویت شده	2.44	205.46	134.66	-6076.5	6097.81

	آزمایشی (Test)				
	ME	RMSE	MAE	MPE	MAPE
درخت بدون تنظیم cp	45.25	257.24	159.98	-1699.24	1729.42
عمیق ترین درخت	42.81	259.43	151.78	-1755.83	1785.94
هرس بر اساس xerror	35.27	252.37	153.56	-1519.28	1547.55
بهترین هرس	49.27	270.35	167.22	-1842.7	1872.237
جنگل تصادفی	44.75	250.03	148.21	-1708.23	1735.54
درخت تقویت شده	39.19	244.94	148.43	-1824.32	1850.7

در بین مدل های مبتنی بر درخت دو مدل جنگل تصادفی و درخت تقویت شده مشترکا توانستند بهرین عملکرد را روی داده های جدید از خود نشان بدهند و به عنوان بهترین مدل های این بخش انتخاب میشوند.

٤. شبکه های عصبی مصنوعی

شبکه های عصبی مصنوعی مدل دیگری است که قصد داریم عملکرد آن را روی داده هایمان بررسی کنیم.

از آن جا آموزش شبکه عصبی با تعداد متغیر های پیشگو نیار به یک شبکه عصبی پیچیده با تعداد نرون های زیاد دارد و این عامل باعث میشود که سرعت یادگیری در شبکه به شدت افت کند قصد داریم که تعداد متغیر های پیشگو را کاهش دهیم و تنها از تعداد انگشت شماری از متغیر ها برای پیشگویی استفاده کنیم اما از آن جا که انتخاب کردن این متغیر ها از داده های اصلی ممکن است باعث میشود بخش زیادی از اطلاعات موجود از بین برود و واریانس کمی از داده ها در متغیر های انتخاب شده وجود داشته باشد، ابتدا قصد داریم که با استفاده از روش PCA مهم ترین ویژگی های داده را به شکل ترکیبی خطی از ویژگی های اولیه داده به دست بیاوریم ، به این شکل با انتخاب کردن تعداد انگشت شماری از این ویژگی ها میتوانیم بخش بزرگی از واریانس داده ها را شناسایی کنیم و از آن برای پیشگویی در مدل استفاده کنیم.

برای این کار لازم است که PCA را روی داده های آموزشی اجرا کنیم و مهم ترین بردار های ویژگی را به دست بیاوریم و مدل ها را روی این ویژگی های جدید آموزش دهیم و سپس برای آزمایش مدل داده های آزمایشی را با استفاده از ترکیب های خطی بهینه یافته شده از داده های آموزشی تبدیل کنیم و سپس از آن برای آزمایش داده ها استفاده کنیم.

برای انجام PCA روی داده های آموزشی به شکل زیر عمل میکنیم.

```
pcs = prcomp(x_train)
```

با اجرای دستور summary روی pcs میتوانیم تاصیر هر یک از بردار ها جدید را بررسی کنیم. بخشی از خروجی این دستور را در زیر مشاهده میکنید.

```
summary(pcs)
```

```
Importance of components:
                          PC1    PC2     PC3     PC4    PC5     PC6     PC7
Standard deviation     0.6277 0.5811 0.47103 0.37583 0.3262 0.28818 0.27791
Proportion of Variance 0.1622 0.1390 0.09133 0.05814 0.0438 0.03419 0.03179
Cumulative Proportion  0.1622 0.3011 0.39247 0.45061 0.4944 0.52859 0.56039
                           PC8     PC9    PC10    PC11    PC12    PC13    PC14
Standard deviation     0.24415 0.20925 0.18287 0.16914 0.16448 0.16150 0.14714
Proportion of Variance 0.02454 0.01802 0.01377 0.01178 0.01114 0.01074 0.00891
Cumulative Proportion  0.58492 0.60295 0.61671 0.62849 0.63962 0.65036 0.65927
                          PC15   PC16    PC17    PC18   PC19    PC20    PC21
Standard deviation     0.13895 0.1314 0.12283 0.12124 0.1187 0.11829 0.11755
Proportion of Variance 0.00795 0.0071 0.00621 0.00605 0.0058 0.00576 0.00569
Cumulative Proportion  0.66722 0.6743 0.68053 0.68658 0.6924 0.69814 0.70383
                          PC22    PC23   PC24    PC25    PC26    PC27    PC28
Standard deviation     0.10725 0.10652 0.1057 0.10496 0.10447 0.10086 0.09893
Proportion of Variance 0.00474 0.00467 0.0046 0.00453 0.00449 0.00419 0.00403
Cumulative Proportion  0.70857 0.71324 0.7178 0.72237 0.72686 0.73105 0.73508
                          PC29    PC30    PC31    PC32    PC33    PC34    PC35
Standard deviation     0.09878 0.09864 0.09794 0.09673 0.09549 0.09450 0.09230
Proportion of Variance 0.00402 0.00401 0.00395 0.00385 0.00375 0.00368 0.00351
Cumulative Proportion  0.73910 0.74310 0.74705 0.75090 0.75466 0.75833 0.76184
                          PC36    PC37   PC38    PC39    PC40    PC41    PC42
Standard deviation     0.09031 0.09016 0.0895 0.08871 0.08845 0.08593 0.08309
Proportion of Variance 0.00336 0.00335 0.0033 0.00324 0.00322 0.00304 0.00284
Cumulative Proportion  0.76520 0.76854 0.7718 0.77508 0.77830 0.78134 0.78418
```

در این جا واریانس پوشش داده شده توسط هر بردار و واریانس تجمعی پوشش داده شده تا آن بردار را مشاهده میکنید.

همان طور که مشاهده میکنیم بردار اول به تنهایی ۱۶ درصد از کل واریانس داده ها را پوشش میدهد.

در این بخش من چندین مدل مختلف با تعداد متغیر های مختلف را بررسی کردم که این توضیح را در کنار هر مدل ذکر خواهم کرد.

مدلی که با ۱۱۲ متغیر ساخته و ۱۰۰ نورون ساختم که تقریبا ۹۰ درصد واریانس داده ها را پوشش میداد بعد از ۱۵ ساعت موفق به همگرا شدن نشد.

مدل های دیگری نیز با تعداد کمتری متغیر ساختم که آن ها نیز همگرا نشدند.

در نهایت دو دسته مدل ساختم که برخی از آن ها از ۹ بردار ویژگی استفاده کردند و برخی دیگر از ۴ بردار ویژگی استفاده کردند.

در این جا روش تبدیل داده های آموزشی اولیه به بردار های جدید را نشان میدهیم.

```
x_train.pca = pcs$x[,1:4]
```

```
head(x_train.pca)
```

	PC1	PC2	PC3	PC4
649	-1.0523432	-0.3145527	0.01584797	-0.32758941
639	-1.0557971	-0.3136770	0.02383819	-0.32541412
241	0.4912139	0.5772892	-0.74522645	-0.07406887
662	0.1159690	-0.9360292	0.19398902	-0.81532686
727	0.2333827	-0.2921811	-1.21826290	0.40104081
276	0.3985958	0.5518737	-0.06038210	-0.08441918

و سپس ستون هدف را به داده های آموزشی وصل میکنیم.

```
train.pca = as.data.frame(cbind(y_train,x_train.pca))
```

```
dim(train.pca)
```

```
614  5
```

```
names(train.pca)
```

```
'y_train'  'PC1'  'PC2'  'PC3'  'PC4'
```

حالا زمان آن رسیده که داده های آزمایشی را نیز به همین فضای حالت ببریم تا بتوانیم آن ها را برای ارزیابی مدل آماده کنیم.

برای این کار ابتدا باید center را در این بردار ها یکی کنیم و سپس به وسیله چرخشی که برای ساخت هر کدام از بردار ها لازم است آن ها را به بردار های جدید تبدیل کنیم.

```
x_test.centered = scale(x_test, center= pcs$center)
x_test.pca = x_test.centered %*% pcs$rotation
x_test.pca = as.data.frame(x_test.pca[,1:4])
```

```
head(x_test.pca)
```

	PC1	PC2	PC3	PC4
1	0.4466654	-0.6028422	-0.71302714	0.7662643
7	-1.1273885	-0.3270660	0.04705929	1.1931403
9	1.2744104	-1.6243480	0.54857499	0.1351745
17	0.5806250	-0.3371365	-0.69636422	0.6781684
20	1.1375791	-1.7468060	0.02827934	0.8414800
23	1.2800244	-1.6435276	0.46315910	0.1964228

```
dim(x_test.pca)
```

```
154  4
```

از تابع فعالسازی logistic و tanh در این مدل ها استفاده میکنیم

و از بهینه ساز resilient backpropagation چون سرعت آن از backpropagation کلاسیک بهتر است و میتوان learning rate را بر صورت پویا و با توجه به مسئله تغییر داد و در شرایطی مختلف learning rate را کم و زیاد میکند.

و برای محاسبه خطا نیز از جمع مربعات خطاها sse استفاده میکنیم.

مدل ۱ : ۹ ویژگی – ۱ لایه مخفی با ۹ نرون

```
nn = neuralnet(formula = y_train ~ ., data = train.pca, hidden = c(9), threshold = 10,
  stepmax = 1e+08 ,algorithm = "rprop+",err.fct = "sse", learningrate.factor = list(minus = .5 ,plus = 1.5),
  act.fct = "logistic", linear.output = TRUE, lifesign = 'full', lifesign.step=100)
```

```
accuracy(as.numeric(compute(nn,train.pca[-c(1)])$net.result),train.pca[,1])
```

	ME	RMSE	MAE	MPE	MAPE
Test set	0.0001031294	218.77	144.8914	-5176.347	5197.467

```
accuracy(as.numeric(compute(nn,x_test.pca)$net.result),y_test)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	372.071	696.6781	538.4502	1794.504	1879.446

بیش برازش روی داده های آموزشی داشته است پس تعداد نرون ها را کمتر میکنیم.

مدل ۲ : ۹ ویژگی – ۱ لایه مخفی با ۷ نرون

```
nn2 = neuralnet(formula = y_train ~ ., data = train.pca, hidden = c(7), threshold = 1,
  stepmax = 1e+04 ,algorithm = "rprop+",err.fct = "sse", learningrate.factor = list(minus = .5 ,plus = 1.5),
  act.fct = "logistic", linear.output = TRUE, lifesign = 'full', lifesign.step=100)
```

```
accuracy(as.numeric(compute(nn2,train.pca[-c(1)])$net.result),train.pca[,1])
```

	ME	RMSE	MAE	MPE	MAPE
Test set	-0.0004841371	277.0954	190.7664	-5182.401	5205.557

```
accuracy(as.numeric(compute(nn2,x_test.pca)$net.result),y_test)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	76.31488	319.4234	216.3862	-2695.067	2737.178

بیش برازش برطرف شد حالا بررسی میکنیم که آیا با تعداد متغیر کمتر هم میتوانیم پیش بینی خوبی روی داده ها داشته باشیم یا خیر

مدل ۳ : ۴ ویژگی – ۱ لایه مخفی با ۷ نرون

```
nn2 = neuralnet(formula = y_train ~ ., data = train.pca, hidden = c(7), threshold = 0.1,
  stepmax = 1e+08 ,algorithm = "rprop+",err.fct = "sse", learningrate.factor = list(minus = .7 ,plus = 1.4),
  act.fct = "logistic", linear.output = TRUE, lifesign = 'full', lifesign.step=100)
```

```
accuracy(as.numeric(compute(nn2,train.pca[-c(1)])$net.result),train.pca[,1])
```

	ME	RMSE	MAE	MPE	MAPE
Test set	-0.000003528016	275.0204	188.7649	-5324.152	5347.422

```
accuracy(as.numeric(compute(nn2,x_test.pca)$net.result),y_test)
```

	ME	RMSE	MAE	MPE	MAPE
Test set	79.53797	319.2327	216.0056	-1366.788	1410.741

عملکرد مدل بهبود یافت.

میتوان این کار را با تعداد ویژگی های مختلف و تعداد نرون های مختلف در لایه های پنهان مجددا انجام داد و نتایج مدل را بهبود داد ، اما به دلیل زیاد شدن محاسبات این آموزش ها نیاز به سیستم های قدرتمند تری دارد و برخی از مدل های بنده بعد از گذشت زمان طولانی همگرا نشدند و به همین دلیل آن ها را در این گزارش ذکر نکردم.

بررسی :

آزمایشی (Test)				
MAPE	MPE	MAE	RMSE	ME
1876.44	1794.5	538.45	696.67	372.07
2737.17	-2695.06	216.38	319.42	76.31
1410.74	-1366.78	216	319.23	79.53

آموزشی (Train)				
MAPE	MPE	MAE	RMSE	ME
5197.46	-5176.34	144.89	218.77	0
5205.55	-5182.4	190.76	277.09	0
5347.42	-5324.15	188.76	275.02	0

۹ ویژگی ۹ نرون
9 ویژگی 7 نرون
۴ ویژگی ۷ نرون

بهترین مدل شبکه عصبی ما مدل شماره ۳ میباشد چون تعداد ویژگی های کمتری نیاز دارد و عملکرد آن نیز نسبت به بقیه مدل های شبکه عصبی روی داده جدید بهتر بود.

مقایسه عملکرد برترین مدل های هر دسته با یکدیگر

در جدول زیر شاخص های مختلف دقت را برای بهرین مدل های هر کدام از این ۴ دسته مشاهده میکنید.

	آموزشی (Train)				
	ME	RMSE	MAE	MPE	MAPE
رگرسیون قدم به قدم پیشرو	0	149.09	102.67	-2555.9	2572.02
6 – نزدیک ترین همسایه	5.84	277.28	182.08	-2107.49	2131.76
جنگل تصادفی	5.2	86.16	55.99	-2299.6	2308.98
درخت تقویت شده	2.44	205.46	134.66	-6076.5	6097.81
مدل سوم شبکه عصبی	0	275.02	188.76	-5324.15	5347.42

آزمایشی (Test)				
ME	RMSE	MAE	MPE	MAPE
63.64	296.67	189.67	-10821.6	10856.77
3.57	215.86	141.81	-4819.53	4840.35
44.75	250.03	148.21	-1708.23	1735.54
39.19	244.94	148.43	-1824.32	1850.7
79.53	319.23	216	-1366.78	1410.74

به نظر من مهم ترین این شاخص ها MAE و RMSE میباشند و به همین دلیل مدل ۶-نزدیک ترین همسایه را به عنوان بهترین مدل انتخاب میکنم.

در این گزارش ابتدا سعی کردیم تا داده های مربوط به خرید و فروش مسکن در استان خوزستان را بررسی کنیم ، به عوامل تاثیر گذار روی قیمت مسکن پرداختیم و سعی کردیم تاثیر هر یک را بر شهرستان های مختلف استان خوزستان آشکار کنیم تا برای شخصی که قصد دارد برای اولین بار با این داده ها کار کند دید کافی را ایجاد کنیم تا بتواند دقیق تر این داده ها را مورد بررسی قرار دهد ، قطعا نکات مهم دیگری نیز در این داده ها وجود دارد که بنده نتوانستم به خوبی آن ها را نمایش دهم.

سپس در بخش دوم با سعی کردیم با استفاده از مدل های مختلف قیمت خانه ها را با توجه به سایر ویژگی هایشان پیشبینی کنیم که نتایج را مشاهده کردید.

این داده ها مشکلاتی نیز داشتند که میتوان به کم بودن تعداد داده ها در شهرستان های مختلف و کم بودن پراکندگی داده ها در برخی از ستون ها اشاره کرد که باعث شد اطلاعات خیلی زیادی برای نمایش و بررسی موجود نباشد.